

UNIVERSIDADE FEDERAL DE SÃO JOÃO DEL-REI

Carlos Henrique Lopes Zansavio

**Um arcabouço computacional para
monitoramento epidemiológico: caso de estudo
Covid-19**

São João Del Rei

2025

UNIVERSIDADE FEDERAL DE SÃO JOÃO DEL-REI

Carlos Henrique Lopes Zansavio

**Um arcabouço computacional para monitoramento
epidemiológico: caso de estudo Covid-19**

Dissertação apresentada como requisito para
obtenção do título de Mestre em Ciência
da Computação do curso de mestrado do
Programa de Pós Graduação em Ciência da
Computação (PPGCC) da UFSJ.

Orientador: Michel Carlo Rodrigues Leles

Coorientador: João Pedro Hallack Sansão

Universidade Federal de São João del-Rei — UFSJ

Mestrado em Ciência da Computação

São João Del Rei

2025

Carlos Henrique Lopes Zansavio

Um arcabouço computacional para monitoramento epidemiológico: caso de estudo Covid-19

Dissertação apresentada como requisito para obtenção do título de Mestre em Ciência da Computação do curso de mestrado do Programa de Pós Graduação em Ciência da Computação (PPGCC) da UFSJ.

Michel Carlo Rodrigues Leles
Orientador

João Pedro Hallack Sansão
Coorientador

Marconi de Arruda Pereira
DTECH/UFSJ

Homero Nogueira Guimarães
DEE/UFMG

São João Del Rei
2025

Resumo

A pandemia de Covid-19 evidenciou fragilidades nos sistemas de monitoramento epidemiológico, demonstrando a necessidade de soluções mais integradas e escaláveis para o acompanhamento de surtos. Este trabalho propõe um arcabouço computacional completo para o monitoramento de doenças, abrangendo desde a coleta e pré-processamento de dados até a visualização interativa, com ferramenta de código aberto. Como prova de conceito, foram usados os dados da pandemia de Covid-19. Foi implementado também, um modelo preditivo, que demonstra a viabilidade de incorporar mecanismos de previsão ao sistema. Portanto, o trabalho contribui com um arcabouço computacional escalável, modular e reprodutível para o monitoramento de surtos, com código-fonte disponível publicamente.

Palavras-chaves: monitoramento epidemiológico; covid-19; arcabouço computacional; código aberto

Abstract

The Covid-19 pandemic exposed weaknesses in epidemiological monitoring systems, highlighting the need for more integrated and scalable solutions for outbreak tracking. This work proposes a complete computational framework for disease monitoring, covering all stages from data collection and preprocessing to interactive visualization, using an open-source tool. As a proof of concept, data from the Covid-19 pandemic were used. A predictive model was also implemented, demonstrating the feasibility of incorporating forecasting mechanisms into the system. Therefore, this work contributes a scalable, modular, and reproducible computational framework for outbreak monitoring, with publicly available source code.

Key-words: epidemiological monitoring, covid-19; framework; open source

Agradecimentos

Agradeço aos meus pais por terem fornecido as ferramentas necessárias para alcançar meus objetivos.

À Daniela por ter me dado o suporte necessário. Sua presença foi um alicerce e um farol para conclusão desse trabalho.

E aos meus amigos pelo companheirismo e pelas palavras de encorajamento.

Lista de ilustrações

Figura 1 – Óbitos novos - dados oficiais	13
Figura 2 – Dados do Rio de Janeiro até o final de Julho/2020	29
Figura 3 – Fluxograma da metodologia de pré-processamento	30
Figura 4 – Fluxograma da Engenharia de Dados	33
Figura 5 – Fluxograma do arcabouço computacional	35
Figura 6 – Linha do tempo - Predição modelo <i>Baseline</i>	41
Figura 7 – Interface do módulo de análise nacional do painel Metabase	43
Figura 8 – Módulo de análise estadual do painel Metabase	44
Figura 9 – Módulo de análise municipal do painel Metabase	45
Figura 10 – Módulo de análise de sobrevivência do painel Metabase	46
Figura 11 – Módulo preditivo no painel do Metabase	47
Figura 12 – Incidência por 100 mil habitantes - boxplot	48
Figura 13 – Mortalidade por 100 mil habitantes - boxplot	49
Figura 14 – Incidência por 100 mil habitantes - linha do tempo	50
Figura 15 – Mortalidade por 100 mil habitantes - linha do tempo	51
Figura 16 – Comparação entre capitais - linha do tempo	52
Figura 17 – Comparação entre capitais - dispersão	53

Lista de tabelas

Tabela 1 – Tabela das cidades com dados anômalos	14
Tabela 2 – Tabela de dados anômalos	14
Tabela 3 – Tabela quantitativa de <i>outliers</i>	38
Tabela 4 – Métricas de desempenho do modelo <i>Naive Baseline</i>	41

Lista de abreviaturas e siglas

SRAG	Síndrome Respiratória Aguda Grave
SIM	Sistema de Informação sobre Mortalidade
SIVEP	Sistema de Vigilância Epidemiológica da Gripe

Sumário

1	Introdução	12
1.1	Contextualização e Motivação	12
1.2	Formulação do problema	12
1.3	Objetivo	15
1.4	Adoção de Metodologia Aberta	16
1.5	Organização do Texto	16
2	Trabalhos Relacionados	17
3	Referencial Teórico	19
3.1	Princípios de Engenharia de <i>Software</i> no <i>framework</i>	19
3.1.1	Princípio de Responsabilidade Única	20
3.1.2	Princípio de Aberto/Fechado	20
3.1.3	Princípio da Substituição de Liskov	20
3.1.4	Princípio da Segregação de Interfaces	21
3.1.5	Princípio da Inversão de Dependência	21
3.2	Limpeza de dados	21
3.2.1	<i>Z-Score</i>	22
3.2.2	<i>One-Hot Encoding</i>	22
3.2.3	<i>Label Encoding</i>	22
3.3	Metabase	23
4	Metodologia	25
4.1	Base de Dados	25
4.1.1	Estrutura da base de dados	26
4.1.2	Limitações e Desafios da Base de Dados	27
4.1.2.1	Atrasos e Revisões nos Dados	27
4.1.2.2	Subnotificação e Heterogeneidade na Vigilância	28
4.1.2.3	Divergências Metodológicas na Temporalidade dos Dados	28
4.1.2.4	Estimativas de Casos Recuperados e suas Limitações	28
4.2	Metodologia Proposta: Pré-processamento da base	28
4.2.1	Estruturação de Dados para Suporte à Análise Epidemiológica	31
4.3	Arquitetura do Sistema de Visualização de Dados	32
4.4	Arcabouço Computacional	32
4.4.1	Arquitetura do <i>framework</i> de Processamento	33
4.4.2	Agrupamento de Arquivos	33

4.4.3	Limpeza e Pré-processamento	33
4.4.4	Engenharia de Atributos	34
4.4.4.1	Seleção de Atributos	34
4.4.4.2	Criação de Atributos Temporais	34
4.4.4.3	Padronização do Nome das Colunas	34
4.4.5	Armazenamento e Consolidação	35
4.4.6	Modularidade do Arcabouço	35
4.5	Modelo computacional	36
5	Resultados	38
5.1	Metodologia de pré-processamento	38
5.2	Engenharia de dados	38
5.2.1	Implementação dos Princípios SOLID	39
5.2.2	Agrupamento dos Arquivos	39
5.2.3	Limpeza dos Arquivos	39
5.2.4	Engenharia de Atributos	40
5.2.5	Carregamento	40
5.3	Modelo Computacional	40
5.4	Metabase	41
5.4.1	Visão Geral do Brasil	42
5.4.2	Minas Gerais	42
5.4.3	Municípios mineiros	43
5.4.4	Análise de risco	45
5.4.5	Predição	47
5.5	Resultados da Análise Epidemiológica	47
5.5.1	Incidência acumulada por 100.000 mil habitantes por porte popu- lacional para os estados da região Sudeste do Brasil	47
5.5.2	Mortalidade acumulada por 100.000 mil habitantes por porte po- pulacional para os estados da região Sudeste do Brasil	48
5.5.3	Incidência acumulada por 100.000 mil habitantes para o período de março de 2020 a março de 2021, comparando a incidência do estado com a da sua respectiva capital	49
5.5.4	Mortalidade acumulada por 100.000 mil habitantes para o período de março de 2020 a março de 2021, comparando a mortalidade do estado com a da sua respectiva capital	50
5.5.5	Comparativo de incidência, mortalidade, número de casos e óbitos acumulados por 100000 habitantes	51
5.5.6	Mortalidade acumulada e número de óbitos acumulados por 100000 habitantes	52

6	Discussão	54
7	Conclusão	56
7.1	Principais Contribuições	57
7.2	Limitações e Desafios	57
7.3	Trabalhos Futuros	58
7.4	Considerações Finais	58
	Referências	60
	Anexos	62
ANEXO A	Logs de Execução do Framework	63
ANEXO B	Logs de Execução do Algoritmo de Agrupamento	65
ANEXO C	Logs de Execução do Algoritmo de Limpeza	66
ANEXO D	Logs de Execução do Algoritmo de Computar Atributos	67
ANEXO E	Logs de Execução do Algoritmo de Carregamento	68
ANEXO F	Código Principal	69
ANEXO G	Trecho do código de Limpeza	70
ANEXO H	Código Suavizar	71

1 Introdução

1.1 Contextualização e Motivação

A pandemia de Covid-19 representou um dos maiores desafios globais das últimas décadas, impactando profundamente a saúde pública, a economia e os comportamentos sociais. Desde o surgimento do SARS-CoV-2, patógeno inicialmente desconhecido, até a adoção de medidas preventivas, como o uso de máscaras e o distanciamento social, a crise exigiu respostas rápidas e baseadas em evidências científicas. Nesse contexto, a Ciência de Dados emergiu como uma ferramenta essencial para compreender a dinâmica da doença, prever sua disseminação e subsidiar políticas públicas eficazes.

Além da resposta emergencial, a pandemia evidenciou lacunas estruturais nos sistemas de vigilância epidemiológica, especialmente no que se refere à integração, análise e interpretação de dados em tempo real. A multiplicidade de fontes de informação — incluindo notificações de casos em localidades remotas — revelou-se tanto uma oportunidade quanto um desafio. O atraso na notificação e, em alguns casos, a completa ausência de repasse de dados dificultaram a obtenção de *insights* estratégicos, comprometendo a agilidade e a precisão na tomada de decisões. A rapidez no rastreamento de doenças é crucial para conter sua disseminação e mitigar seus impactos, tornando-se um fator determinante para a eficácia das ações de controle.

Embora o cenário atual da Covid-19 seja considerado controlado, a emergência de novas variantes, como a XFG — recentemente identificada no Rio de Janeiro pelo Instituto Oswaldo Cruz — evidencia a permanência de riscos epidemiológicos e a necessidade de vigilância contínua (MENEZES; NERI, 2025). Simultaneamente, o estado de Minas Gerais vivencia um aumento significativo nos casos de doenças respiratórias agudas graves, o que motivou a decretação de situação de emergência em saúde pública pelo governo estadual (SECOM, 2025). Tal medida também foi adotada por diversos municípios mineiros, em resposta à crescente pressão sobre os serviços de saúde locais (MILAGRES, 2025). Esses episódios reforçam a importância do monitoramento constante e da resposta rápida diante de novas ameaças sanitárias, a fim de evitar a sobrecarga do sistema de saúde, como ocorreu durante os momentos mais críticos da pandemia.

1.2 Formulação do problema

Diante desse cenário, torna-se urgente o desenvolvimento de *frameworks* robustos que possibilitem o monitoramento contínuo de doenças com base em dados multidimen-

sionais. Os impactos da pandemia deixaram claro que muitas mortes poderiam ter sido evitadas com um sistema de rastreamento mais eficiente e coordenado. O receio de enfrentar uma nova doença com potencial de causar prejuízos semelhantes aos da Covid-19 reforça a necessidade de se dispor, com antecedência, de ferramentas capazes de serem rapidamente implantadas assim que um surto for identificado.

Atualmente, a ferramenta oficial do governo para monitoramento da Covid-19 é o portal covid.saude.gov.br. No entanto, esta plataforma não oferece a flexibilidade necessária para análises personalizadas e aprofundadas por parte de pesquisadores e profissionais de saúde. Além da falta de tratamento dos dados, que será discutida na seção 4.1.2 e pode ser visualizado na figura 1.



Figura 1 – Óbitos novos - dados oficiais

Percebe-se que o painel na Figura 1 exibe dados negativos de óbitos, o que não faz sentido nenhum. Uma análise exploratória nos dados até Julho de 2020 revela o mesmo comportamento nos novos casos. Diante disso, procedeu-se à filtragem do conjunto para o período compreendido entre 30/05/2020 e 15/06/2020. Esses valores atípicos encontram-se detalhados na Tabela 1.

Tabela 1 – Tabela das cidades com dados anômalos

Município	Conselheiro Lafaiete	Ouro Branco	Rio de Janeiro	São João del Rei
2020-05-31	0	1	676	0
2020-06-01	1	0	857	2
2020-06-02	0	0	1.190	3
2020-06-03	6	0	1.747	2
2020-06-04	3	0	744	5
2020-06-05	27.232	9.758	1.374.992	21.453
2020-06-06	-27.229	-9.752	-1.372.984	-21.449
2020-06-07	1	0	412	8
2020-06-08	3	0	778	1
2020-06-09	0	2	1.010	1
2020-06-10	3	2	1.057	8
2020-06-11	0	1	1.057	5
2020-06-12	4	0	487	11
2020-06-13	3	1	907	6
2020-06-14	3	1	357	5

Conforme evidenciado na Tabela 1, observa-se que nos dias 5 e 6 de junho de 2020 ocorreu um pico abrupto na ordem de grandeza de milhões, contrastando significativamente com os valores previamente registrados, que se mantinham na escala de milhares em diversas cidades.

Os dados mostrados sugerem que alguma coisa extraordinária ocorreu nos dados oficiais no dia 05/06/2020 e uma tentativa de correção foi feita no dia 06/06/2020; o que não é um caso isolado apenas do dia mencionado, como podemos observar na Tabela 2. Essa anomalia também aparece em outras datas.

Tabela 2 – Tabela de dados anômalos

Município	Estado	Data	Casos novos
Tefé	AM	2020-07-05	-443
Campo Verde	MT	2020-07-21	-403
Campo Verde	MT	2020-07-16	-381
Niterói	RJ	2020-05-26	-349
Mogi Mirim	SP	2020-07-29	-334
Campos de Júlio	MT	2020-07-22	-328
Armação dos Búzios	RJ	2020-06-25	-252
Campos de Júlio	MT	2020-07-17	-251
Tefé	AM	2020-06-25	-244
Lucas do Rio Verde	MT	2020-07-18	-208

Esse cenário compromete a validade de qualquer análise baseada nesses dados, uma vez que a ocorrência de valores negativos em casos e óbitos novos indica inconsistências graves. Diante disso, torna-se necessária a aplicação de métodos de tratamento e correção

desses registros. Contudo, verifica-se uma lacuna na literatura, com escassez de estudos específicos sobre técnicas de pré-processamento de dados para esse tipo de anomalia.

A solução proposta se diferencia das ferramentas existentes justamente por permitir que epidemiologistas e demais usuários possam criar suas próprias análises e visualizações a partir dos dados já pré-processados. Esta abordagem proporciona maior autonomia para investigações científicas e tomadas de decisão baseadas em evidências, superando as limitações das plataformas atualmente disponíveis.

Além disso, este trabalho é parte integrante do projeto *Fapemig* intitulado ‘APQ-02152-21: Buscando Pontos de Mudança nas Séries Temporais de COVID-19 do Estado de Minas Gerais’, com foco na parte computacional que subsidia o trabalho epidemiológico (FARIAS, 2025). Ressalta-se, portanto, que o escopo aqui apresentado restringe-se ao desenvolvimento da plataforma computacional, enquanto a análise epidemiológica propriamente dita será detalhada em trabalho complementar.

1.3 Objetivo

Desenvolver um *framework* para monitoramento de doenças baseado em dados, com capacidade de escalabilidade e flexibilidade, visando aprimorar a vigilância epidemiológica em contextos pandêmicos, surtos locais e doenças endêmicas, além de propor uma técnica de pré-processamento dos dados oficiais da Covid-19.

Como objetivos específicos, temos:

Integração de dados: Implementar um sistema que consolide fontes de dados heterogêneas (clínicos, demográficos, geográficos e temporais) em um formato unificado e acessível.

Processamento e análise: Propor método para pré-processamento, enriquecimento e modelagem dos dados, garantindo qualidade e consistência para análises epidemiológicas.

Flexibilidade analítica: Proporcionar uma plataforma que permita a epidemiologistas e gestores em saúde criar análises personalizadas, adaptáveis a diferentes cenários e necessidades.

Visualização interativa: Implementar *dashboards* dinâmicos para monitoramento em tempo real, identificação de tendências e geração de alertas precoces.

Aplicação em cenário real: Aplicar o *framework* aos dados da Covid-19 como prova de conceito, demonstrando sua utilidade para reconstrução histórica, vigilância ativa e projeções futuras.

Metodologia aberta: Adotar metodologia aberta, que possibilita outros pesqui-

sadores contribuam e se beneficiarem deste trabalho.

Como resultado, espera-se ter uma ferramenta que permite intervenções mais rápidas com dados pré-processados mais confiáveis, validados por epidemiologistas, fortalecendo assim a capacidade de resposta da saúde pública.

1.4 Adoção de Metodologia Aberta

Este trabalho foi desenvolvido com base em princípios de ciência aberta, buscando não apenas apresentar resultados, mas também disponibilizar ferramentas e processos que possam ser reutilizados e aprimorados pela comunidade acadêmica e técnica.

Como parte dessa iniciativa, todo o código-fonte implementado foi disponibilizado publicamente no repositório github.com/carloszan/covid, permitindo a reprodução dos experimentos, a adaptação para novos contextos e a evolução colaborativa da solução. O repositório contém todo o *framework* proposto, além das análises feitas por este estudo.

Optou-se por escolher tecnologias acessíveis e abertas que possibilitam total reprodutibilidade por toda a comunidade científica.

1.5 Organização do Texto

O capítulo 2 traz os Trabalhos Relacionados, que oferece uma revisão das abordagens existentes. A seguir, no capítulo 3, o Referencial Teórico aprofunda os conceitos fundamentais que sustentam a metodologia adotada. No 4º capítulo, a Metodologia detalha as etapas do desenvolvimento do *framework*, incluindo a descrição da base de dados, os desafios encontrados, as estratégias de engenharia de dados e a arquitetura do sistema de visualização. Os resultados são apresentados no 5º capítulo com aplicação prática das técnicas e ferramentas descritas, evidenciando a eficácia do *framework*. Por fim, o capítulo 6 é abordada a Discussão que reflete os aprendizados e limitações do estudo, culminando na Conclusão, discutida no capítulo 7, que resume as principais contribuições e aponta direções para trabalhos futuros.

2 Trabalhos Relacionados

A Covid-19 tornou-se, um objeto de estudo de extrema relevância para a comunidade científica. Desde sua primeira descrição detalhada no trabalho de (SHI, 2020), que destacou as características clínicas e epidemiológicas do vírus, pesquisadores em todo o mundo têm se dedicado a investigar seus impactos e padrões de disseminação. Ademais, a forma como a doença se espalhou foi diferente em cada região do mundo. Por isso, além de uma análise geral para a busca de padrões, se faz necessário também estudos segmentados por localidades.

No âmbito regional, estudos específicos sobre a Covid-19 em Minas Gerais, como os apresentados em (RODRIGUES; ORTEGA, 2023), (SANTOS, 2024) e (OLIVEIRA; NOBRE, 2023), têm utilizado fontes de dados robustas, como o Sistema de Informação da Vigilância Epidemiológica da Gripe (SIVEP-Gripe), que monitora casos de Síndrome Respiratória Aguda Grave (SRAG). Esses trabalhos contribuem para a compreensão da dinâmica da doença a nível local, oferecendo insights valiosos para a tomada de decisões em saúde pública.

Apesar de todos eles utilizarem a mesma fonte de dados, o (SHI, 2020) usa de modelos flexíveis de regressão e florestas aleatórias de sobrevivência para comparar duas ferramentas de análise de sobrevivência em pacientes com Covid-19. A análise de sobrevivência também é um tópico de interesse desse trabalho e fará parte do relatório interativo proposto.

Já o segundo é um estudo descritivo e quantitativo para analisar o perfil epidemiológico dos casos e mortes por SRAG, com foco em Covid-19 em MG durante 2021 a 2023. De forma análoga, este trabalho pretende dispor em um relatório interativo, análises desses perfis focados no estado de MG.

E o terceiro usa métodos de *Machine Learning* (*DecisionTree*, *Random Forest*, *Neural Networks* e *Naive Bayes*) para prever hospitalizações de Covid-19. Este trabalho não tem como foco a construção de modelos preditivos ou descritivos, embora essa seja uma possibilidade promissora para pesquisas futuras. O objetivo aqui é demonstrar como os dados gerados por esse tipo de modelo também podem ser integrados a *dashboards* analíticos, ampliando a capacidade de análise e visualização, à medida que oferecem tanto um relato histórico quanto uma possível projeção de cenários futuros.

Diferentemente dos três autores citados acima, (FERNANDES, 2023) extraiu dados da base DataSUS/TABNet no período de jan/2018 a dez/2021 para comparar a ocorrência de morbimortalidade por pneumonia no Estado da Bahia, no período pré e durante a pandemia de COVID-19. Para isso, utilizou de estatística descritiva, frequência

relativa e estatística analítica com teste de frequências relativas U de *Maan-Whitney*.

Com o objetivo de estudar a diferença de letalidade e incidência entre os estados de MG e ES, (SILVA, 2024) fez uma análise de dados temporais sobre a base extraída do site covid.saude.gov.br, que é a mesma fonte usada por este projeto. Porém, esse trabalho não menciona uma solução para o problema exposto na Seção 1.2. Uma das análises do trabalho de (SILVA, 2024) será reproduzida no *framework* proposto, com intuito de comparação e tentativa de reprodutibilidade dos indicadores em uma mesma base de interesse.

Além disso não foram encontrados na literatura outros trabalhos que abordam técnicas de pré-processamento para esses dados.

O expressivo volume de estudos publicados sobre a Covid-19 evidencia seu relevante interesse científico e a importância contínua desta linha de pesquisa, principalmente com uma fonte de dados confiáveis.

3 Referencial Teórico

Um *framework* pode ser definido como uma estrutura modular e reutilizável que fornece um conjunto de princípios, padrões e ferramentas para o desenvolvimento de sistemas complexos, visando aumentar a eficiência, a consistência e a manutenibilidade do *Software*. No contexto deste trabalho, a discussão sobre os princípios de engenharia de *Software* se justifica pela necessidade de garantir que o *framework* proposto seja robusto, adaptável e capaz de lidar com os desafios inerentes ao processamento e análise de dados epidemiológicos. Além disso, destaca-se a importância da limpeza e padronização dos dados, uma etapa crítica em *frameworks* de engenharia e análise de dados, uma vez que a qualidade das informações impacta diretamente a confiabilidade dos resultados gerados. Ademais, ferramentas como o Metabase desempenham um papel importante, fornecendo funcionalidades de visualização e exploração interativa de dados, o que consolida o *framework* como uma solução completa para o monitoramento de doenças.

Este capítulo apresenta os fundamentos teóricos que embasam o desenvolvimento do *framework* proposto, abordando conceitos essenciais de Engenharia de *Software*, técnicas de pré-processamento de dados e ferramentas de análise e visualização.

Na Seção 3.1, são discutidos os princípios de Engenharia de *Software* aplicados ao *framework*, incluindo requisitos de escalabilidade, modularidade e integração de sistemas, que garantem a robustez e adaptabilidade da solução proposta.

A Seção 3.2 trata das técnicas de limpeza e preparação de dados, etapas críticas para assegurar a qualidade e consistência das informações antes da análise. São apresentados métodos para tratamento de outliers, normalização e transformação de variáveis, fundamentais para análises epidemiológicas confiáveis.

Por fim, a Seção 3.3 descreve o Metabase, uma ferramenta de *business intelligence open-source* utilizada para consultas, análises e visualização interativa de dados. São destacadas suas funcionalidades, vantagens e como sua integração ao *framework* possibilita a criação de *dashboards* dinâmicos e acessíveis para usuários não técnicos.

3.1 Princípios de Engenharia de *Software* no *framework*

A arquitetura de *Software* desempenha um papel crítico na construção de sistemas robustos e adaptáveis, especialmente em contextos de saúde pública, onde a confiabilidade e a manutenibilidade são essenciais. Os princípios SOLID - acrônimo formado pelas iniciais dos cinco princípios que o compõem (*Single Responsibility*, *Open-Closed*, *Liskov Substitution*, *Interface Segregation* e *Dependency Inversion*) - concebidos em (MARTIN,

2000), oferecem diretrizes valiosas para o desenvolvimento de *frameworks* que demandam alta coesão, baixo acoplamento e facilidade de extensão. A aplicação desses princípios no contexto do monitoramento epidemiológico justifica-se pela necessidade de sistemas que possam evoluir continuamente, incorporando novas fontes de dados, algoritmos e requisitos regulatórios sem comprometer a estabilidade do sistema existente.

A adoção dos princípios SOLID viabiliza ainda a colaboração eficiente de equipes multidisciplinares no desenvolvimento e evolução da ferramenta. Ao estabelecer módulos bem definidos com responsabilidades claras e interfaces estáveis, diferentes especialistas - como epidemiologistas, cientistas de dados e engenheiros de *Software* - podem trabalhar de forma paralela e coordenada, cada um focando em seu domínio específico sem gerar conflitos ou dependências críticas. Essa característica é particularmente valiosa em sistemas de saúde pública, onde a agilidade na incorporação de novos conhecimentos científicos e requisitos operacionais é fundamental para o sucesso da vigilância epidemiológica.

3.1.1 Princípio de Responsabilidade Única

O Princípio da Responsabilidade Única estabelece que cada módulo do *framework* deve ter uma única razão para mudar (MARTIN, 2000), o que se alinha diretamente com a modularização proposta neste trabalho. Por exemplo, o módulo de coleta de dados deve ser independente do módulo de análise preditiva, permitindo que atualizações em um não afetem o outro. Durante a pandemia de Covid-19, sistemas monolíticos enfrentaram dificuldades para adaptar-se a novas variáveis, como a inclusão de dados de mobilidade urbana, enquanto abordagens modulares demonstraram maior resiliência (MOORTHY, 2020).

3.1.2 Princípio de Aberto/Fechado

O Princípio do Aberto/Fechado defende que entidades de *Software* devem estar abertas para extensão, mas fechadas para modificação (MARTIN, 2000). No contexto deste *framework*, isso se traduz na capacidade de adicionar novos modelos preditivos ou fontes de dados sem alterar o núcleo do sistema. A adoção de interfaces bem definidas permite que futuras integrações sejam implementadas sem riscos à estrutura existente.

3.1.3 Princípio da Substituição de Liskov

O Princípio da Substituição de Liskov assegura que objetos derivados devem ser substituíveis por seus objetos base sem alterar a corretude do programa (MARTIN, 2000). Na prática, isso implica que extensões do *framework* — como um novo algoritmo de detecção de anomalias — devem manter compatibilidade com os contratos estabelecidos pelos módulos centrais. Violações desse princípio, como modelos preditivos que exigem

pré-processamentos incompatíveis, podem introduzir erros cascadeantes em sistemas de vigilância em tempo real.

3.1.4 Princípio da Segregação de Interfaces

O Princípio da Segregação de Interfaces recomenda que interfaces sejam específicas para cada cliente, evitando dependências desnecessárias (MARTIN, 2000). Em sistemas de saúde, onde diferentes atores (gestores, epidemiologistas, desenvolvedores) consomem dados de formas distintas, a criação de interfaces dedicadas reduz a complexidade e aumenta a eficiência.

3.1.5 Princípio da Inversão de Dependência

Por fim, o Princípio da Inversão de Dependência enfatiza que módulos de alto nível não devem depender de módulos de baixo nível, mas ambos devem depender de abstrações (MARTIN, 2000). A experiência durante a Covid-19 mostrou que sistemas rígidos, com acoplamento elevado, tornaram-se obsoletos diante da necessidade de integrar rapidamente novas fontes, como dados de testes rápidos em farmácias (WARD, 2020).

3.2 Limpeza de dados

A etapa de limpeza de dados representa um pré-requisito fundamental para qualquer análise de dados confiável, particularmente no contexto epidemiológico onde decisões críticas dependem da qualidade da informação. Dados brutos frequentemente contêm inconsistências que podem comprometer os resultados e análises. Por isso é importante identificar e remover *outliers*. Algumas técnicas para tratar isso são *Z-Score* e Média Móvel.

O tratamento de dados constitui uma etapa no processo analítico, onde os dados previamente limpos são transformados e enriquecidos para possibilitar análises mais robustas e confiáveis. Além da remoção de *outliers*, este processo também envolve a criação de novas variáveis derivadas que capturam relações mais complexas nos dados.

Duas técnicas amplamente aplicadas no tratamento de dados são *One-Hot Encoding* e *Label Encoding*. Essas técnicas são usadas em variáveis categóricas, definidas como aquelas que assumem um número limitado de valores discretos representando grupos ou categorias.

As técnicas citadas serão abordadas nas seções a seguir.

3.2.1 Z-Score

O *Z-Score*, também conhecido como *Standard Scaler* (ANDRADE, 2021), é uma técnica estatística fundamental para padronização de dados, amplamente utilizada em processamento de dados e aprendizado de máquina. Seu principal objetivo é transformar as variáveis em uma escala comum, facilitando comparações e melhorando o desempenho de algoritmos sensíveis à magnitude dos dados.

$$z = \frac{x - \mu}{\sigma}$$

onde x é o valor original, μ é a média da *feature* e σ é o seu desvio padrão.

No contexto deste trabalho, o *Z-Score* foi aplicado para normalizar variáveis epidemiológicas, assegurando que métricas como incidência, casos novos e mortalidade fossem comparáveis em análises temporais e geográficas.

3.2.2 One-Hot Encoding

One-Hot Encoding é uma técnica fundamental de pré-processamento de dados utilizada para a codificação de variáveis categóricas em formatos numéricos compatíveis com algoritmos de aprendizado de máquina. O método consiste na transformação de cada categoria distinta em uma nova coluna binária (0 ou 1), onde a presença de um valor 1 indica a pertinência da observação àquela categoria específica (RODRÍGUEZ, 2018).

Esta abordagem é particularmente relevante quando as variáveis categóricas não apresentam uma relação ordinal ou hierárquica entre si, garantindo que o modelo não interprete erroneamente relações numéricas inexistentes. Contudo, o *One-Hot Encoding* pode levar ao aumento significativo da dimensionalidade do conjunto de dados (problema conhecido como "*curse of dimensionality*"), especialmente quando aplicado a variáveis com alta cardinalidade. Para mitigar este efeito, técnicas complementares como seleção de características ou redução de dimensionalidade são frequentemente empregadas.

A implementação do *One-Hot Encoding* é amplamente suportada por bibliotecas de processamento de dados como Pandas (função `get_dummies`) e Scikit-learn (classe `OneHotEncoder`), sendo considerada uma etapa essencial no *pipeline* de preparação de dados para modelos que requerem entrada estritamente numérica, como redes neurais e algoritmos baseados em distâncias métricas.

3.2.3 Label Encoding

Label Encoding é uma técnica de pré-processamento de dados utilizada para converter variáveis categóricas em representações numéricas, atribuindo a cada categoria

única um valor inteiro distinto (JIA; ZHANG, 2021). Diferentemente do *One-Hot Encoding*, que cria colunas binárias para cada categoria, o *Label Encoding* mapeia as categorias diretamente em valores discretos (e.g., "Baixo"= 0, "Médio"= 1, "Alto"= 2).

A implementação do *Label Encoding* é facilitada por bibliotecas como Scikit-learn, por meio da classe `LabelEncoder`, que automatiza o mapeamento das categorias para valores inteiros. A técnica é computacionalmente eficiente, pois não aumenta a dimensionalidade dos dados, sendo preferível em casos onde a cardinalidade das variáveis categóricas é elevada e a relação ordinal é bem definida. Contudo, para categorias nominais (sem ordem natural), recomenda-se o uso de alternativas como *One-Hot Encoding* ou técnicas de *embedding* para evitar viés nos modelos.

3.3 Metabase

O Metabase é uma plataforma de análise de dados de código aberto que permite explorar, visualizar e compartilhar informações de maneira intuitiva, sem a necessidade de conhecimentos técnicos avançados em análise de dados ou SQL (SANTOS, 2019). Ele é amplamente utilizado por empresas e organizações para extrair *insights* de seus bancos de dados. Nele, pode-se criar perguntas, consultas, *dashboards*, coleção, modelos e métricas.

Sua arquitetura modular e interface amigável possibilitam a criação de diversos artefatos analíticos, incluindo perguntas ad-hoc, consultas complexas, *dashboards* interativos, coleções organizadas de visualizações, modelos de dados estruturados e métricas padronizadas. O sistema é amplamente adotado por organizações de saúde e pesquisa, demonstrando especial eficácia no tratamento de dados epidemiológicos complexos (BUDIARTI, 2023).

A plataforma oferece conectividade nativa com os principais sistemas de gerenciamento de banco de dados, incluindo PostgreSQL, MySQL e Microsoft SQL Server, tornando-se particularmente adequada para integrar-se com a arquitetura SQL implementada neste projeto. Sua capacidade de processar grandes volumes de dados epidemiológicos com desempenho satisfatório foi um fator determinante em sua seleção.

A seguir são descritos alguns conceitos do Metabase.

As perguntas são consultas criadas no Metabase para obter informações a partir dos dados. Elas podem ser feitas de forma visual, por meio da interface intuitiva.

As consultas são *scripts* em SQL para buscar e retornar dados de um banco. Elas permitem maior flexibilidade, mas exige um nível de conhecimento em SQL.

As variáveis são elementos inseridos em consultas para permitir ajustes dinâmicos de parâmetros durante a sua execução.

Uma variável em SQL é definida com chaves duplas. Exemplo:


```
SELECT * FROM dados_covid  
WHERE categoria = {{categoria}}
```

Os trechos são fragmentos reutilizáveis de consultas SQL, criados para facilitar o uso de partes comuns de código em diferentes consultas. Um trecho pode ser referenciado usando a sintaxe `{{#snippet nome_do_trecho}}`, sendo substituído automaticamente pelo código correspondente durante a execução.

Os modelos são abstrações ou camadas personalizadas criadas sobre tabelas ou consultas existentes para facilitar a reutilização. Eles simplificam o trabalho ao permitir que usuários finais acessem dados já estruturados de maneira lógica. Além de permitir uma melhor performance, já que os dados são persistidos. Porém modelos não podem conter variáveis, já que são como consultas pré processadas.

As métricas são medidas específicas e padronizadas usadas para avaliar o desempenho ou monitorar indicadores-chave (KPIs). Elas são definidas com base em tabelas ou consultas e podem ser reutilizadas em diferentes relatórios ou *dashboards*. Métricas também não podem conter variáveis.

Os filtros são ferramentas que permitem aos usuários ajustar os resultados exibidos em perguntas e *dashboards* de forma visual, sem precisar modificar diretamente a consulta ou o código. Um filtro pode ser associado a uma variável para dinamizar as consultas SQL.

As coleções são pastas organizacionais usadas para armazenar e categorizar perguntas, *dashboards*, modelos e outros objetos criados na plataforma. Elas podem ser organizadas em hierarquias (coleções principais e subcoleções), com permissões configuráveis para controlar o acesso de usuários e grupos, garantindo que apenas as pessoas autorizadas possam visualizar ou modificar os conteúdos.

Os *dashboards* são conjuntos de visualizações organizadas em um painel único, permitindo acompanhar múltiplas métricas e *insights* ao mesmo tempo. Ele é composto pelas perguntas, consultas e métricas citadas anteriormente. Além de cabeçalhos, textos e filtros.

4 Metodologia

Este capítulo apresenta a estrutura metodológica adotada no estudo, detalhando os procedimentos desde a coleta e preparação dos dados até a análise e visualização. A metodologia está organizada em seis seções principais, cada uma abordando aspectos essenciais para a condução da pesquisa.

A primeira seção, Base de Dados (4.1), descreve a origem, composição e limitações dos dados utilizados, com foco em suas dimensões geográficas, temporais, demográficas e epidemiológicas. Em seguida, a seção Pré-processamento (4.2) discute as técnicas aplicadas para identificar e tratar inconsistências, como valores nulos e *outliers*, além de análises preliminares para compreensão dos padrões nos dados.

A Arquitetura do Sistema de Visualização (4.3) explica a infraestrutura desenvolvida para permitir a representação gráfica e interativa dos dados, enquanto a Engenharia de Dados (4.4) detalha as etapas de processamento, desde a limpeza e transformação até o armazenamento e aplicação de modelos analíticos.

Por fim, a seção Modelos (4.5) apresenta as abordagens estatísticas ou preditivas empregadas para extrair *insights* e responder às questões de pesquisa.

4.1 Base de Dados

A base de dados principal utilizada neste estudo consiste nas informações oficiais sobre casos e óbitos por Covid-19 no Brasil, disponibilizadas diariamente pelo Ministério da Saúde, em parceria com as Secretarias Estaduais e Municipais de Saúde. Esses dados são consolidados a partir dos registros enviados pelas 27 Unidades Federativas e divulgados publicamente por volta das 19h, representando a situação epidemiológica mais atualizada. Esta seção descreve a estrutura da base, suas variáveis e sua relevância para estudos em saúde pública.

Os dados foram coletados do DataSUS, no *link* <https://covid.saude.gov.br>, integrando informações sobre casos confirmados, óbitos, recuperados e outras métricas relacionadas à Covid-19. A base segue um formato longitudinal, com registros diários, organizados de forma hierárquica (município → estado → região), o que permite análises em diferentes níveis geográficos.

Os principais sistemas e fontes utilizados para a construção dessa base de dados incluem:

- Sistema de Vigilância Epidemiológica da Gripe (SIVEP-Gripe): Registra casos de

Síndrome Respiratória Aguda Grave (SRAG) hospitalizados e óbitos por SRAG, sendo essencial para análises temporais por data de ocorrência.

- **e-SUS VE:** Sistema utilizado para notificação de casos de síndrome gripal, complementando os dados de vigilância.
- **Sistema de Informação sobre Mortalidade (SIM):** Fornece registros de óbitos, permitindo correções e análises mais precisas.
- **Estimativas populacionais do DATASUS:** Utilizadas para cálculo de indicadores como incidência e mortalidade, baseadas em projeções do Tribunal de Contas da União (TCU) para 2019.

4.1.1 Estrutura da base de dados

A base é composta por múltiplas colunas, que podem ser categorizadas em:

Identificadores Geográficos

- **regiao:** Nome da região do Brasil (Norte, Nordeste, Sul, Sudeste, Centro-Oeste).
- **estado:** Unidade da Federação (UF) correspondente.
- **municipio:** Município de ocorrência do registro.
- **coduf:** Código numérico do estado.
- **codmun:** Código IBGE do município.
- **codRegiaoSaude:** Código da região de saúde.
- **nomeRegiaoSaude:** Nome da região de saúde conforme divisão do Ministério da Saúde.
- **interior/metropolitana:** Classificação do município como área metropolitana ou interiorana, sendo 0 para interior e 1 para metropolitana.

Identificadores Temporais

- **data:** Data do registro.
- **semanaEpi:** Semana epidemiológica, seguindo o padrão do sistema de vigilância em saúde, variando de 0 a 52 semanas por ano.

Dados Demográficos

- **populacaoTCU2019**: População estimada do município em 2019, conforme dados do Tribunal de Contas da União (TCU).

Dados Epidemiológicos

- **casosAcumulado**: Total acumulado de casos confirmados até a data de referência.
- **casosNovos**: Número de novos casos registrados no dia.
- **obitosAcumulado**: Total acumulado de óbitos confirmados.
- **obitosNovos**: Novos óbitos registrados no dia.
- **Recuperadosnovos**: Número de pacientes recuperados recentemente.
- **emAcompanhamentoNovos**: Casos em acompanhamento ativo.

4.1.2 Limitações e Desafios da Base de Dados

Apesar dos esforços de consolidação e divulgação de dados epidemiológicos pelo Ministério da Saúde em parceria com as Secretarias Estaduais e Municipais de Saúde, a base de dados sobre Covid-19 no Brasil apresenta limitações significativas, as quais devem ser consideradas em análises científicas e tomadas de decisão.

O processo de atualização das informações nos municípios, estados e na esfera federal é dinâmico e complexo, como mencionado na página ‘Sobre’ em (SAUDE, 2020). Os dados informados diariamente são sujeitos a alterações. Considerando a pluralidade de cada município brasileiro no que diz respeito a porte populacional, infraestrutura e organização dos serviços de saúde, além de todos os desafios que a pandemia de Covid-19 impõe, é possível que haja mudanças no número de casos ou óbitos em decorrência de erros ou atrasos no repasse das informações. Em nível municipal, o dado do dia atual pode ser menor que o do dia anterior, o que ocorre porque o município de notificação não é necessariamente o mesmo local de residência do caso ou óbito notificado. Assim, ao concluir o processo de investigação de cada ocorrência individualmente, as Secretarias Municipais e Estaduais de Saúde possuem autonomia para corrigir a informação e repassá-la ao Ministério da Saúde. Vale ressaltar que os casos e óbitos são atualizados por data de notificação, e que o Ministério da Saúde vem trabalhando em conjunto com as Secretarias Estaduais e Municipais de Saúde para aprimorar continuamente a divulgação desses indicadores.

4.1.2.1 Atrasos e Revisões nos Dados

Um dos principais desafios é a natureza dinâmica da notificação, que pode sofrer ajustes retroativos. Municípios, especialmente aqueles com menor estrutura de saúde, fre-

quentemente revisam seus registros, levando a discrepâncias entre os números divulgados inicialmente e os consolidados posteriormente. Esse fenômeno é particularmente relevante em análises temporais, uma vez que a atualização tardia de casos e óbitos pode distorcer a percepção da curva epidemiológica em tempo real.

4.1.2.2 Subnotificação e Heterogeneidade na Vigilância

A subnotificação de casos e óbitos constitui uma limitação crítica, influenciada pela disponibilidade desigual de testes e pela capacidade diferenciada de vigilância entre estados e municípios. Regiões com menor acesso a testes, como algumas áreas do Norte e Nordeste, tendem a apresentar subestimativas mais acentuadas. Além disso, a notificação depende da integração entre sistemas de saúde públicos e privados, o que pode gerar lacunas na captação de dados, especialmente em locais com maior fragmentação dos serviços.

4.1.2.3 Divergências Metodológicas na Temporalidade dos Dados

Outra limitação relevante é a discrepância entre a data de notificação e a data de ocorrência de casos e óbitos. Enquanto os dados oficiais são divulgados por data de registro, a análise epidemiológica mais precisa requer a utilização de informações por data de início dos sintomas ou data do óbito, disponíveis em sistemas como o SIVEP-Gripe e o SIM. Essa diferença metodológica pode levar a interpretações equivocadas sobre o momento real de picos e quedas na transmissão.

4.1.2.4 Estimativas de Casos Recuperados e suas Limitações

A quantificação de casos recuperados é particularmente desafiadora devido à escassez de testes laboratoriais para confirmação da cura. No Brasil, adota-se um método indireto, que combina dados de hospitalizações (SIVEP-Gripe) e um critério temporal (14 dias após o início dos sintomas para casos leves) (DIAS, 2020). Essa abordagem, embora necessária, pode superestimar ou subestimar o número real de recuperados, já que não considera assintomáticos ou casos com prolongamento da infecção.


4.2 Metodologia Proposta: Pré-processamento da base

A análise exploratória evidenciou o problema das notificações descritas na Seção 4.1.2 e brevemente abordada na Seção 1.2.



Conforme registros coletados até julho de 2025, a base de dados analisada compreende 10.390.399 entradas. Dessa forma, optou-se por fazer um recorte dos dados até Julho de 2020, ficando com total de 714.481 registros. Esse subconjunto permitiu análises e protótipos mais rápidos no intuito de desenvolver a metodologia proposta.

Identificou-se a presença de valores nulos nos campos referentes a municípios e estados. Considerando que tais inconsistências poderiam comprometer a validade da análise, optou-se pela remoção desses registros.

Diante da descoberta de anomalias, aplicou-se o método *Z-score*, conhecido para remoção de *outliers*, mencionado na Seção 3.2.1. Após a aplicação desse método, observa-se o real formato da curva de casos novos, na Figura 2b. Entretanto, é perceptível os picos de notificação e para resolver isso, foi aplicado média móvel, na tentativa de suavização da série temporal, conforme Figura 2c.



(a) Dados crus

(b) Após aplicação do *Z-score*

(c) Após aplicação da Média Móvel

Figura 2 – Dados do Rio de Janeiro até o final de Julho/2020

Ainda assim, mesmo após a aplicação das duas técnicas mencionadas, permaneceram registros com valores negativos. Essas técnicas foram eficazes em eliminar os erros mais grosseiros, restando apenas valores negativos de pequena magnitude. Sendo assim,

o último passo do pré-processamento proposto consiste na remoção dos valores negativos residuais. É conhecido que se um valor negativo foi inserido, provavelmente existe um correspondente positivo com a correção desse dado. Optou-se por mantê-los no conjunto de dados a fim de preservar a fidelidade às bases oficiais e evitar distorções em relação ao que foi originalmente inserido no sistema. Acredita-se que esses positivos residuais não alterem tanto a característica da curva real, como os outros *outliers* encontrados e removidos.

A simples remoção desses valores negativos não resolveria integralmente o problema, pois continuariam presentes picos artificiais decorrentes de inserções equivocadas e de suas respectivas correções. Por isso, buscou-se uma técnica capaz de capturar a dinâmica temporal desses eventos — identificando os picos e vales que representam tanto o erro de inserção quanto a sua retificação — em vez de apenas tratar o conjunto de forma agregada.

Essa decisão, além de preservar a integridade do processo de coleta, também favorece a reprodutibilidade: outros pesquisadores podem acessar exatamente o mesmo cenário encontrado e, a partir dele, adotar diferentes estratégias de tratamento conforme suas necessidades analíticas. Ao mesmo tempo, foram suavizados os erros mais grosseiros presentes na base original, de modo que o resultado final buscou oferecer uma representação mais fidedigna do cenário real, sem os efeitos distorcivos de valores exorbitantes.




Figura 3 – Fluxograma da metodologia de pré-processamento

A Figura 3 descreve o algoritmo com todas as técnicas descritas, sendo (i) remoção de nulos, aplicação de (ii) *Z-score* e (iii) média móvel e (iv) remoção de negativos restantes.

Vale ressaltar que o pré-processamento deve ser feito em cada município para que uma mesma janela não englobe dois municípios.

Além disso, a variável de casos acumulados deve ser recalculada, já que ela depende de casos novos. Sendo assim, para manter a consistência pós limpeza, é necessário recalculá-la.

Tendo em vista as descobertas descritas acima, a abordagem metodológica combina as técnicas mencionadas com ferramentas Python para tratar os dados. O algoritmo proposto para pré-processamento dos dados advindos do DataSUS é o seguinte:

- Identifica municípios únicos (combinação município/estado), removendo dados com município faltante

- Agrupa os dados por município e estado
- Aplica para cada grupo a função ‘limpar’, que é composta pelas técnicas descritas na Seção 4.2
- Une todos os grupos processados e retorna um conjunto final tratado

Vale reforçar que a função `limpar` cumpre o papel de aplicar a média móvel, sobre os casos novos, logo após a remoção de *outliers* por *Z-score*. Além de recalcular os casos acumulados, como pode ser visualizado no Anexo G.

Com os dados tratados, foi possível estruturar análises juntamente com uma equipe de epidemiologistas, que será discutida na Seção 4.2.1.

4.2.1 Estruturação de Dados para Suporte à Análise Epidemiológica

Foi realizada uma análise epidemiológica em conjunto com especialistas da área, com o objetivo de compreender os principais aspectos da base de dados e validar sua aplicabilidade em um estudo de avaliação do impacto da pandemia de Covid-19 nos municípios da região Sudeste, considerando fatores socioeconômicos, estruturais e medidas governamentais.

A partir dos dados tratados, foram elaborados gráficos que serviram de suporte ao trabalho ‘Análise epidemiológica de Covid-19 nos estados brasileiros no primeiro ano de pandemia’ de (FARIAS, 2025), que compara os estados do Sudeste brasileiro, em relação a indicadores epidemiológicos e infraestrutura hospitalar, como número de leitos. Conforme destacado no capítulo 1, este estudo está vinculado ao projeto *Fapemig* intitulado ‘APQ-02152-21: Buscando Pontos de Mudança nas Séries Temporais de Covid-19 do Estado de Minas Gerais’, que investiga pontos de mudança nas séries temporais de Covid-19 em Minas Gerais. Enquanto o presente trabalho aborda o sistema computacional, a análise epidemiológica dos resultados é desenvolvida em (FARIAS, 2025).

Para a construção desses gráficos, foi feito um trabalho em conjunto de elaboração e refinamento iterativo das análises epidemiológicas. Além da busca e incorporação de dados externos com o propósito de enriquecer as análises — como o número de leitos de UTI nos estados da região Sudeste, bem como os feriados nacionais e estaduais. Esses insumos complementares foram essenciais para contextualizar os resultados obtidos no trabalho de (FARIAS, 2025), que evidenciaram, por exemplo, a maior vulnerabilidade do Espírito Santo em comparação a Minas Gerais, mesmo em regiões com melhores recursos hospitalares.

4.3 Arquitetura do Sistema de Visualização de Dados

Após a etapa de exploração e validação da qualidade dos dados, procede-se ao desenvolvimento da arquitetura do sistema de visualização. O *dashboard* foi projetado com uma estrutura modular organizada em cinco abas principais, cada uma com objetivos analíticos específicos:

- **Visão Geral Histórica do Brasil:** Apresenta uma análise temporal da evolução da doença em nível nacional, permitindo identificar tendências e padrões epidemiológicos ao longo do tempo.
- **Minas Gerais:** Foca na análise regional, destacando particularidades do estado que concentra o estudo, com indicadores-chave e comparações intraestaduais.
- **Comparação entre Municípios:** Oferece ferramentas analíticas para avaliação comparativa entre diferentes cidades, enfatizando indicadores demográficos e de saúde pública.
- **Predições:** Permite a incorporação de dados advindos de modelos estatísticos e de *machine learning* para projeções de cenários futuros, baseados em séries temporais.
- **Análise de Risco e Sobrevivência:** Utiliza técnicas de análise de sobrevivência e avaliação de risco para mostrar e avaliar os índices de mortalidade e sobrevivência.

Esta estrutura divide-se em duas dimensões analíticas: as quatro primeiras abas concentram-se na análise retrospectiva (passado e presente), enquanto a última é dedicada à análise prospectiva (projeções futuras).

A arquitetura foi desenvolvida considerando princípios de *design* centrado no usuário, garantindo intuitividade e eficácia na comunicação das informações. A implementação utiliza ferramentas modernas de visualização de dados, como Metabase, garantindo escalabilidade e performance mesmo com grandes volumes de dados.

4.4 Arcabouço Computacional

A arquitetura de dados do projeto foi concebida para assegurar eficiência, escalabilidade e manutenibilidade, adotando uma abordagem modular que distingue claramente as funções de armazenamento e processamento. Para o armazenamento, optou-se por um Sistema de Gerenciamento de Banco de Dados Relacional (SGBDR) SQL, escolhido por sua capacidade de preservar a integridade dos dados mediante um esquema relacional bem estruturado, além de oferecer controle transacional robusto, suporte a consultas complexas e mecanismos confiáveis de backup e recuperação.

Essa arquitetura foi proposta para processar dados e carregá-los no Metabase e para análises epidemiológicas, como utilizadas no trabalho de (FARIAS, 2025). O pré-processamento pode ser encontrado na seção 4.2. Uma ilustração pode ser encontrada na Figura 4.




Figura 4 – Fluxograma da Engenharia de Dados

4.4.1 Arquitetura do *framework* de Processamento

A camada de processamento de dados foi concebida como um *framework* orientado a objetos em Python, adotando os princípios SOLID, apresentado na Seção 3.1, que conferem três propriedades essenciais: extensibilidade modular, adaptabilidade a diferentes contextos epidemiológicos e robustez operacional. Esta abordagem sistêmica atende aos requisitos de um sistema de vigilância em saúde que demanda constante evolução para incorporar novas doenças, fontes de dados e metodologias analíticas.

A arquitetura implementa o paradigma de *pipeline* modular, onde cada etapa de transformação dos dados é encapsulada em componentes independentes que seguem contratos bem definidos por interfaces abstratas.

4.4.2 Agrupamento de Arquivos

A primeira etapa consiste na consolidação das diversas fontes de dados em um formato unificado. Os dados brutos, provenientes de múltiplos arquivos CSV, são coletados e organizados em uma estrutura padronizada. Este processo inclui a verificação da completude dos arquivos, validação de metadados e registro de eventuais inconsistências encontradas na carga inicial. A implementação utiliza bibliotecas como Pandas para garantir eficiência no tratamento da grande quantidade de dados.

4.4.3 Limpeza e Pré-processamento

Os dados agregados passam pelo processo de limpeza e suavização, conforme detalhado na Seção 4.2. Inicialmente, aplica-se uma rotina automatizada de validação que identifica e corrige inconsistências nos valores coletados, incluindo a detecção de registros duplicados, valores fora do domínio esperado e padrões anômalos nas séries temporais.

A implementação considera as particularidades temporais e geográficas dos dados, ajustando os parâmetros de suavização conforme o município e o período analisado.

Os resultados deste processamento são validados através de comparação com *benchmark* epidemiológico conhecido como Painel Interativo que temos dentro do próprio <https://covid.saude.gov.br>.

O conjunto de dados resultante apresenta coerência temporal e espacial adequada para as análises subsequentes e modelagem preditiva.

4.4.4 Engenharia de Atributos

A etapa de engenharia de atributos foi estruturada em três subprocessos sequenciais, conforme detalhado a seguir.

4.4.4.1 Seleção de Atributos

Realizou-se a eliminação de duas colunas que não são o foco dessa pesquisa:

- `Recuperadosnovos`
- `emAcompanhamentoNovos`

4.4.4.2 Criação de Atributos Temporais

Foram derivados oito novos atributos a partir da variável temporal original, visando enriquecer a análise epidemiológica:

- Atributos numéricos: `ano`, `mês_numerico`, `dia_semana_numerico`
- Atributos categóricos: `mês`, `mês_traduzido`, `dia_semana`, `dia_semana_traduzido`
- Atributo sazonal: `estação` (primavera, verão, outono, inverno)

4.4.4.3 Padronização do Nome das Colunas

Efetuuou-se a normalização dos nomes das colunas para seguir as boas práticas de nomenclatura em ciência de dados:

- Conversão para *snake_case*
- Remoção de caracteres especiais (e.g., `"/"em interior/metropolitana`)
- Unificação de termos (e.g., `Acumulado` → `acumulados`)

4.4.5 Armazenamento e Consolidação

A etapa final gerencia o armazenamento estruturado dos dados processados e resultados analíticos no banco de dados SQL. Implementa-se um esquema relacional otimizado para consultas frequentes no *dashboard*, com índices estratégicos e particionamento temporal quando aplicável. A carga no banco é realizada através de transações atômicas, com fallbacks automáticos em caso de falha, assegurando a consistência dos dados disponíveis para visualização.

4.4.6 Modularidade do Arcabouço

Os processos descritos nas subseções anteriores podem ser adaptados ou substituídos conforme o contexto ou o tipo de doença analisada. A principal restrição a ser observada refere-se às entradas e saídas de arquivos, que devem manter o mesmo formato e estrutura definidos pelo sistema, conforme a Figura 5.




Figura 5 – Fluxograma do arcabouço computacional

Os dados de entrada devem ser armazenados no diretório `dados/raw/[data da extração]`, correspondente à etapa de extração.

Já o processo de limpeza de dados pode incorporar novas técnicas ou seguir o método padrão proposto, de acordo com as necessidades específicas do estudo. Além disso, a ordem de execução dos subprocessos de limpeza pode ser alterada, desde que a integridade do fluxo de dados seja preservada.

A engenharia de atributos é feita dentro da etapa de computar atributos, onde é possível padronizar nomes de colunas, assim como enriquecer os dados.

O arcabouço também permite a integração com diferentes bancos de dados, possibilitando maior flexibilidade e escalabilidade do sistema.

Os dados processados e salvos em um banco de dados podem servir de entrada para modelos computacionais, como é o caso deste trabalho. A Seção 4.5, a seguir, descreverá como o modelo foi desenvolvido.

4.5 Modelo computacional

Modelos computacionais permitem a previsão de resultados e a compreensão de fenômenos complexos em diversas áreas. Devido ao escopo inicial do trabalho, optou-se por implementar apenas um modelo computacional aplicado à epidemiologia, como prova de conceito, priorizando a avaliação da integração entre o *framework* e as metodologias de previsão.

Para essa validação, utilizou-se a biblioteca **Darts**, uma ferramenta flexível e abrangente para previsão de séries temporais em Python. O Darts foi escolhido por sua capacidade de integrar diferentes modelos de *machine learning* e estatísticos, além de oferecer funcionalidades para pré-processamento, avaliação e comparação de desempenho.

Para a etapa de validação da abordagem proposta, optou-se por construir um modelo simples, mas que representasse de forma mais fiel a estrutura dos dados, indo além de uma previsão puramente ingênua. A construção desse modelo seguiu o raciocínio apresentado na documentação oficial da biblioteca Darts (HERZEN, 2022), que propõe o uso combinado de componentes sazonais e de tendência como ponto de partida para problemas de previsão de séries temporais.

O primeiro componente considerado foi o *NaiveSeasonal*, que parte do princípio de que os dados possuem comportamento cíclico. Esse modelo possui como principal parâmetro o valor de K , que define o número de períodos considerados na repetição do padrão sazonal. Nesse caso, adotou-se $K = 14$, com base no comportamento conhecido da COVID-19: segundo o Ministério da Saúde (SAUDE, 2020), "para os casos leves, a OMS estima que tempo entre o início da infecção e a recuperação dure até 14 dias", o que sugere um ciclo médio de aproximadamente 14 dias na evolução dos indicadores epidemiológicos. Assim, o modelo *NaiveSeasonal*($K=14$) projeta os valores futuros com base na repetição dos últimos 14 pontos observados, reproduzindo o último ciclo identificado na série. O modelo foi treinado com dados referentes ao ano de 2020 e realizou previsões para os dois primeiros meses de 2021.

Entretanto, a aplicação isolada do modelo sazonal não foi suficiente para capturar a tendência global presente nos dados. Para isso, foi incorporado também o modelo *NaiveDrift*, que estima uma linha de tendência para a série com base na diferença entre os valores inicial e final do conjunto de treinamento. Essa abordagem introduz um componente de crescimento ou declínio progressivo, ausente na modelagem puramente sazonal. Conforme a documentação do Darts (HERZEN, 2022), para uma série de treino

de comprimento T , o valor previsto no horizonte h é:

$$\hat{y}_{T+h} = y_T + h \left(\frac{y_T - y_1}{T - 1} \right)$$

A partir da soma direta das previsões geradas por ambos os modelos — sazonal e de tendência — foi obtido o modelo final, denominado *Naive Baseline*. Essa combinação simples, porém eficaz, permite capturar simultaneamente os padrões cíclicos e a evolução ao longo do tempo, servindo como uma base de comparação para avaliar o desempenho de modelos mais sofisticados.

A divisão dos dados foi realizada de forma temporal, utilizando o conjunto de 2020 para treinamento e os dois primeiros meses de 2021 para teste. O desempenho do modelo foi avaliado por meio das métricas Root Mean Squared Error (RMSE) e Mean Absolute Error (MAE), permitindo quantificar a acurácia das previsões obtidas, que se mostrou satisfatória para o objetivo deste trabalho.

A implementação desse modelo no *framework* teve como objetivo principal testar a estrutura de *pipeline* de dados, garantindo que a integração entre coleta, processamento e previsão fosse viável antes da incorporação de técnicas mais avançadas. Os resultados obtidos com o *Naive Baseline* forneceram um ponto de partida para análises comparativas futuras, além de validar a arquitetura proposta para a inclusão de modelos de previsão.

5 Resultados

Este capítulo apresenta os principais resultados obtidos ao longo da pesquisa, organizados em etapas que refletem o processo de análise e modelagem dos dados.

Os resultados aqui expostos fornecem subsídios para a discussão crítica no próximo capítulo, permitindo avaliar a eficácia das metodologias aplicadas e suas implicações para o problema de pesquisa.

5.1 Metodologia de pré-processamento

As técnicas de pré-processamento propostas foram capazes de suavizar as séries temporais de cada município, além de remover grande parte dos *outliers*. Sabe-se que ainda restou alguns resíduos de correções de dados, já que na última etapa, se remove os negativos, mas seus correspondentes positivos se mantêm. Tais resíduos positivos, entretanto, apresentam magnitude significativamente menor em comparação ao cenário anterior ao pré-processamento.

A Tabela 3 mostra o número de *outliers* encontrados em cada etapa do pré-processamento e a porcentagem que eles representam em relação a base de entrada, que continha 714.481 registros. Como citado na Seção 4.2, o período do conjunto de dados compreende desde o início da pandemia até julho de 2020, para essa análise.

Tabela 3 – Tabela quantitativa de *outliers*

Técnica	<i>outliers</i>	Porcentagem
Remoção de nulos	7.091	0,99%
<i>Z-score</i>	18,274	2.55%
Remoção de Negativos	1.983	0,31%

Foram removidos 7.091 registros na etapa de Remoção de nulos, conforme a Tabela 3. Subsequentemente, foi aplicado o *Z-score* (Seção 3.2.1), que resultou na remoção de 2,55% da base. Por fim, os valores negativos restantes, cerca de 0,31%, foram removidos.

Posteriormente, o pré-processamento desenvolvido foi aplicado em todos os dados e os resultados serão mostrados nas seções a seguir.

5.2 Engenharia de dados

A implementação da arquitetura de dados proposta demonstrou eficácia no processamento e transformação dos dados epidemiológicos, atendendo aos requisitos de SOLID

definidos na Seção 3.1. Os resultados obtidos em cada etapa do *pipeline* de engenharia de dados são apresentados nesta seção.

5.2.1 Implementação dos Princípios SOLID

O código principal, disponível no Anexo F, implementa as etapas do processamento de dados, seguindo o primeiro conceito do SOLID, descrito na Seção 3.1.1. O primeiro princípio estabelece que um método deve ser responsável por uma única função. O código em análise adere a esse conceito, uma vez que apresenta funções distintas para: (i) agrupamento de dados, (ii) limpeza, (iii) computação de atributos e (iv) carregamento dos dados em um banco de dados SQL. Um segundo princípio facilmente observado é o *Liskov Substitution* (Seção 3.1.3), onde um pesquisador pode substituir uma função por outra, sem afetar o resto do código. Um exemplo seria um pesquisador desenvolver ou aprimorar o código de pré-processamento, alterando a função **limpar**, que se encontra no Anexo G, mantendo o contrato já estabelecido, sem afetar outras etapas.

Além disso, o *log* completo de execução pode ser encontrado no Anexo A. As etapas do *framework* são analisadas nas seções a seguir.

5.2.2 Agrupamento dos Arquivos

O processo de agrupamento alcançou, em média, um tempo de execução de **25.75 segundos**, considerando as últimas quatro execuções registradas nos *logs*. Os *logs* individuais podem ser visualizados no Anexo B. Em relação aos princípios de escalabilidade e robustez do código, é possível analisar

Foram processados doze arquivos no formato CSV (*Comma-Separated Values*), os quais foram consolidados e convertidos para o formato Apache Parquet (VOHRA, 2016), um sistema de armazenamento colunar otimizado para *big data*. Essa conversão resultou em uma redução significativa de 97,8% no volume de armazenamento, com o tamanho total dos arquivos diminuindo de 936 MB (formato CSV) para apenas 20 MB (formato Parquet).

E a consistência no tempo de processamento indica que o agrupamento é uma operação eficiente, mantendo-se dentro de um intervalo próximo mesmo em horários distintos de execução. A pequena variação pode estar relacionada ao volume de arquivos processados ou à carga do sistema no momento da execução.

5.2.3 Limpeza dos Arquivos

O processo de limpeza alcançou, em média, um tempo de execução de **144 segundos**, considerando as últimas quatro execuções registradas nos *logs*. Os tempos individuais podem ser encontrados no Anexo C.

5.2.4 Engenharia de Atributos

A média de tempo de execução para engenharia de atributos foi **151.2 segundos**. Os tempos individuais de cada execução podem ser visualizadas no Anexo D.

A tabela 5.1 descreve o mapeamento completo das colunas. Essas colunas podem ser utilizadas como indicadores nos gráficos.

Listing 5.1 – Mapeamento completo de renomeação de colunas

<code>regiao</code>	: <code>regiao</code>
<code>estado</code>	: <code>estado</code>
<code>municipio</code>	: <code>municipio</code>
<code>coduf</code>	: <code>coduf</code>
<code>codmun</code>	: <code>codmun</code>
<code>codRegiaoSaude</code>	: <code>cod_regiao_saude</code>
<code>nomeRegiaoSaude</code>	: <code>nome_regiao_saude</code>
<code>data</code>	: <code>data</code>
<code>semanaEpi</code>	: <code>semana_epi</code>
<code>populacaoTCU2019</code>	: <code>populacao_tcu_2019</code>
<code>casosAcumulado</code>	: <code>casos_acumulados</code>
<code>casosNovos</code>	: <code>casos_novos</code>
<code>novos_casos_novos</code>	: <code>novos_casos_novos</code>
<code>obitosAcumulado</code>	: <code>obitos_acumulados</code>
<code>obitosNovos</code>	: <code>obitos_novos</code>
<code>Recuperadosnovos</code>	: <code>recuperados_novos</code>
<code>emAcompanhamentoNovos</code>	: <code>em_acompanhamento_novos</code>
<code>interior/metropolitana</code>	: <code>interior_metropolitana</code>
<code>novos_casos_acumulados</code>	: <code>novos_casos_acumulados</code>


5.2.5 Carregamento

Esta etapa representa o processo mais demorado do fluxo de trabalho, com um tempo médio de execução de **14.331 segundos** (aproximadamente **3 horas, 58 minutos e 51 segundos**). Os registros detalhados estão no Anexo E.

5.3 Modelo Computacional

A implementação do modelo *Naive Baseline*, conforme descrito na Seção 4.5, foi treinada sobre os dados de 2020 e produziu os seguintes resultados de desempenho na previsão dos dois primeiros meses de 2021:

Observa-se que as previsões obtidas reproduziram de maneira consistente a tendência global e o padrão cíclico da série, atendendo ao propósito dos dois componentes

Figura 6 – Linha do tempo - Predição modelo *Baseline*

empregados — *NaiveSeasonal* e *NaiveDrift* — de capturar, respectivamente, a sazonalidade e a evolução temporal. Essa combinação mostrou-se eficaz para representar o comportamento geral dos dados, mas apresentou limitações na identificação de picos abruptos, o que ocasionou discrepâncias pontuais entre valores observados e estimados. Embora a magnitude dessas diferenças não seja elevada, o erro residual indica que há margem para aprimoramentos futuros, sobretudo na modelagem de variações súbitas. Ainda assim, pela sua simplicidade e capacidade de capturar dois componentes fundamentais da série temporal, o modelo configura-se como um ponto de partida sólido para comparações com abordagens mais sofisticadas, em trabalhos futuros.

Os resultados quantitativos obtidos nas séries temporais de teste estão sumarizados na Tabela 4:

Tabela 4 – Métricas de desempenho do modelo *Naive Baseline*

Métrica	Valor	Intervalo de Confiança (95%)
MAE	25,19	(18,44–32,44)
RMSE	38,84	(24,44–55,31)

A confecção de um modelo simples, cumpre o objetivo desse trabalho que era a integração de um modelo preditivo ao *framework*.

5.4 Metabase

O painel interativo desenvolvido e disponível no link <https://metabase.sjdr.cloud/public/dashboard/8a44ac7c-d9ef-49da-bf04-a254dd51c0a7> foi estruturado em

cinco módulos principais, organizados de acordo com os níveis de granularidade espacial e tipos de análise:

- *Visão geral do Brasil* - Análise macroepidemiológica nacional
- *Minas Gerais* - Detalhamento estadual
- *Municípios mineiros* - Análise em nível municipal
- *Análise de risco/sobrevivência* - Análise de Letalidade
- *Predição* - Modelos preditivos

A arquitetura modular permite adaptação a diferentes contextos epidemiológicos mediante substituição dos conjuntos de dados e parâmetros específicos.

5.4.1 Visão Geral do Brasil

A Figura 7 apresenta o painel de análise nacional, que reúne uma visualização agregada de casos por região do país e serve como filtro interativo para as demais informações.

Ao clicar em uma das barras que representam as regiões, os dois gráficos subsequentes exibem as séries temporais de casos e óbitos por estado daquela região. Essa seleção também atualiza um mapa interativo do Brasil, que destaca os estados pertencentes à região escolhida e exibe o acumulado de casos em cada um deles. A partir do mapa, é possível selecionar um estado específico para que os dois gráficos seguintes mostrem, em formato de bolhas, o número de casos e óbitos por município. Nesse formato, os municípios mais afetados aparecem no topo, enquanto um grande agrupamento se concentra na base. Por fim, uma tabela paginada permite explorar os dados em maior detalhe, possibilitando a ordenação por casos, óbitos ou nome dos municípios.

5.4.2 Minas Gerais

Após a visão geral do Brasil, o painel se aprofunda na análise do estado de Minas Gerais, disponível na segunda aba do *dashboard*. A Figura 8 apresenta o módulo estadual, que permite acompanhar a evolução anual da doença por meio de um filtro para seleção do ano desejado.

O módulo inclui:

- **Mapa de casos** - um mapa de calor destacando os municípios com maior número de casos acumulados no ano selecionado;




Figura 7 – Interface do módulo de análise nacional do painel Metabase

- **Métricas por tipo de município** - um gráfico de barras comparando casos e óbitos entre municípios metropolitanos e do interior;
- **Pizzas sazonais** - um gráfico de casos e outro de óbitos distribuídos pelas estações do ano;
- **Casos por ano** - e um gráfico de linhas dos casos de Covid-19, no qual cada linha representa um ano desde o início da pandemia, em 2020.

Esse último gráfico é interativo: ao clicar em uma linha correspondente a um ano, o filtro é atualizado automaticamente e o gráfico ao lado exibe casos e óbitos semanais daquele período. Essa visualização evidencia que a curva de óbitos tende a se deslocar para a direita em relação à de casos, acompanhando, porém, sua tendência geral.

5.4.3 Municípios mineiros

A terceira aba do *dashboard* aprofunda a análise a nível municipal, permitindo a comparação entre dois municípios de Minas Gerais. A Figura 9 apresenta a interface dessa etapa, que dispõe de dois campos de filtro para digitação dos nomes dos municípios desejados.




Figura 8 – Módulo de análise estadual do painel Metabase

A página de visualização é dividida simetricamente ao meio, exibindo os mesmos tipos de gráficos para ambos os municípios, o que facilita a comparação direta. Cada lado apresenta quatro visualizações:

- **Indicador de casos totais** — representado por um gráfico do tipo velocímetro (*gauge chart*), que compara o total de casos do município com a média estadual de Minas Gerais. O mostrador é dividido em três faixas: de 0 a 3.000 casos (abaixo da média), de 3.000 a 7.000 (média estadual) e acima de 7.000 (acima da média).
- **Indicador de óbitos** — gráfico similar ao anterior, porém dedicado ao total de óbitos acumulados no município, também em comparação com a média estadual.
- **Taxa de mortalidade** — métrica que relaciona o número de óbitos ao número de casos, permitindo identificar municípios com proporções mais elevadas ou reduzidas em relação ao estado.




Figura 9 – Módulo de análise municipal do painel Metabase

- **Evolução temporal** — gráfico de linhas que mostra a variação de casos e óbitos ao longo do tempo no município selecionado, facilitando a análise de tendências e picos epidêmicos.

Essa estrutura permite identificar rapidamente diferenças e semelhanças entre municípios, tanto em termos absolutos quanto relativos, considerando o contexto estadual.

5.4.4 Análise de risco

O painel de análise de risco permite a comparação entre os estados de Minas Gerais (MG) e Espírito Santo (ES) a partir de três indicadores centrais:

- **Incidência** — número de casos confirmados em relação à população, permitindo avaliar a intensidade da disseminação da doença nos dois estados.
- **Mortalidade** — total de óbitos registrados em relação à população, indicando o impacto letal da doença em cada estado.
- **Letalidade** — proporção de óbitos entre os casos confirmados, revelando a gravidade média da doença em cada localidade.

Tais indicadores foram definidos no trabalho de (SILVA, 2024), apresentado no capítulo 2. É importante salientar que, por utilizar da mesma fonte de dados deste trabalho, optou-se por reproduzir os mesmos gráficos com dados processados no Metabase.

Os resultados podem ser visualizados na Figura 10. Adicionalmente, o recurso de linha de tendência — também empregado no estudo (SILVA, 2024) — está disponível na ferramenta e pôde ser incorporado aos gráficos para enriquecer a análise.



Figura 10 – Módulo de análise de sobrevivência do painel Metabase

Diferente do (SILVA, 2024), optou-se por dispor cada estado em um gráfico, lado a lado, o invés de inserir as duas curvas no mesmo gráfico, para que uma não distorcesse o eixo da outra e ficasse mais evidente a direção da linha de tendência.

Pode-se observar que os dados de Incidência e Mortalidade estão em concordância com os resultados reportados no estudo (SILVA, 2024). Em relação à letalidade, observa-se uma discreta discrepância entre os dados, particularmente no pico registrado em abril de 2021 em Minas Gerais, onde o estudo aponta um valor superior a 4,5%, enquanto o Metabase registra 4%. Padrão semelhante é verificado no Espírito Santo, cuja letalidade é maior que 4% no estudo, enquanto no Metabase se mantém menor do que 4%. Essa leve assimetria nos dados pode sugerir a ausência de tratamento durante a etapa de pré-processamento, a qual não foi detalhada no estudo de (SILVA, 2024).

Pela característica dinâmica do Metabase, outra decisão de projeto foi incluir no painel um filtro temporal por ano, que possibilita ajustar a análise para períodos específicos, facilitando a comparação entre diferentes momentos da epidemia nos dois estados.

5.4.5 Predição

Por fim, a última aba do painel (Figura 11) exibe os resultados gerados pelo modelo preliminar, concebido e documentado na Seção 4.5, com resultados mostrados na Seção 5.3.




Figura 11 – Módulo preditivo no painel do Metabase

O módulo de predição apresenta uma visualização clara e intuitiva na forma de um gráfico de linhas, que contrasta de maneira eficaz os valores reais observados (em azul) com as previsões geradas pelo modelo (em laranja). Essa comparação visual permite uma avaliação imediata do desempenho do modelo, destacando acertos, discrepâncias e tendências ao longo do período analisado.

5.5 Resultados da Análise Epidemiológica

Para o trabalho descrito na seção 4.2.1 foram produzidos seis visualizações.

5.5.1 Incidência acumulada por 100.000 mil habitantes por porte populacional para os estados da região Sudeste do Brasil

Gráfico 12 apresenta uma análise comparativa da incidência de casos por 100 mil habitantes nos quatro estados da região Sudeste (São Paulo, Rio de Janeiro, Minas Gerais e Espírito Santo), estratificada por porte populacional.

O gráfico é composto por quatro painéis (um para cada estado), cada um contendo cinco *boxplots* que representam as categorias:

- Pequeno I - até 10.000 habitantes
- Pequeno II - de 10.000 até 50.000 habitantes
- Médio - de 50.000 a 100.000 habitantes
- Grande - de 100.000 a 500.000 habitantes
- Metrôpole - maior que 500.000 habitantes




Figura 12 – Incidência por 100 mil habitantes - boxplot

Essa visualização permite avaliar a distribuição e variabilidade da incidência em diferentes tamanhos populacionais, destacando possíveis discrepâncias entre regiões menos e mais populosas.

5.5.2 Mortalidade acumulada por 100.000 mil habitantes por porte populacional para os estados da região Sudeste do Brasil

Gráfico 13 segue a mesma estrutura do anterior, porém com foco na mortalidade acumulada por 100 mil habitantes. Cada estado é representado por um painel com cinco *boxplots*, organizados por porte populacional. A comparação entre os gráficos de incidência e mortalidade permite identificar se padrões semelhantes se repetem para óbitos ou se há divergências significativas.




Figura 13 – Mortalidade por 100 mil habitantes - boxplot

5.5.3 Incidência acumulada por 100.000 mil habitantes para o período de março de 2020 a março de 2021, comparando a incidência do estado com a da sua respectiva capital

Gráfico 14 exibe a evolução temporal da incidência em cada estado do Sudeste, comparando a média estadual com os dados da respectiva capital. São quatro gráficos de linhas (um por estado), cada um com duas curvas: a amarela representa a incidência média no estado e a azul na capital do estado. Essa abordagem revela se as capitais acompanham a tendência estadual ou se apresentam dinâmicas distintas, como surtos mais acentuados.




Figura 14 – Incidência por 100 mil habitantes - linha do tempo

5.5.4 Mortalidade acumulada por 100.000 mil habitantes para o período de março de 2020 a março de 2021, comparando a mortalidade do estado com a da sua respectiva capital

Gráfico 15 repete a estrutura do 14, mas substitui a incidência pela mortalidade acumulada. A sobreposição das linhas permite verificar se as capitais tiveram taxas de óbito proporcionalmente maiores ou menores que a média do estado ao longo do período analisado.




Figura 15 – Mortalidade por 100 mil habitantes - linha do tempo

5.5.5 Comparativo de incidência, mortalidade, número de casos e óbitos acumulados por 100000 habitantes

No gráfico 16, são exibidas quatro séries temporais distintas, uma para cada capital do Sudeste, permitindo uma análise comparativa entre múltiplas métricas ao longo do tempo. Cada painel contém quatro linhas: a primeira representa a incidência (casos por 100 mil habitantes), a segunda mostra a mortalidade (óbitos por 100 mil habitantes), a terceira exhibe novos casos e a quarta traz os óbitos acumulados.




Figura 16 – Comparação entre capitais - linha do tempo

Essa disposição facilita a visualização de correlações, como o intervalo entre picos de casos e subsequentes aumentos na mortalidade, além de revelar discrepâncias entre as capitais. Por exemplo, é possível observar se uma cidade registrou alta incidência, mas mortalidade proporcionalmente menor, sugerindo diferenças na eficácia de políticas públicas ou capacidade hospitalar.

5.5.6 Mortalidade acumulada e número de óbitos acumulados por 100000 habitantes

Gráfico 17 utiliza gráficos de dispersão para explorar relações entre mortalidade, óbitos acumulados e disponibilidade de leitos de UTI. A visualização é dividida em quatro painéis: os dois primeiros focam nas capitais, comparando mortalidade por 100 mil habitantes com o número de leitos de UTI no primeiro painel e óbitos acumulados com leitos no segundo. Os dois painéis seguintes repetem a mesma análise, mas consideram a média

dos estados, permitindo contrastar o desempenho das capitais com o cenário estadual mais amplo.




Figura 17 – Comparação entre capitais - dispersão

Cada ponto no gráfico representa uma unidade geográfica, destacando possíveis associações, como menores taxas de mortalidade em regiões com maior número de leitos, ou *outliers* que sugerem outros fatores influentes, como subnotificação ou variações na qualidade da assistência médica.

6 Discussão

A metodologia proposta neste estudo, aliada aos resultados apresentados no Capítulo 5, confirma a viabilidade e relevância da implementação de um *framework* flexível e escalável para o monitoramento de doenças. Embora tenha sido empregada no contexto da pandemia de Covid-19, conforme detalhado nas análises da Seção 5.4 (“Metabase”), a arquitetura desenvolvida foi projetada para ser adaptável, permitindo seu uso no rastreamento de outras enfermidades com ajustes mínimos, desde que sejam seguidos os procedimentos estabelecidos na metodologia.

O pré-processamento disposto na Seção 4.2 combinou o uso das técnicas de *Z-score* e média móvel. Enquanto a etapa inicial corrige valores anômalos e assegura a detecção de discrepâncias em relação à distribuição geral dos dados, a segunda suaviza a série, preservando a coerência temporal. Por fim, a remoção de valores negativos foi necessária para garantir a consistência dos dados processados, já que casos novos e óbitos negativos não fazem sentido no mundo real. O resultado desse tratamento exibido na Seção 5.1 mostrou-se eficaz na mitigação de ruídos e *outliers*, preservando as características essenciais das séries temporais. Essas etapas foram determinantes para que as visualizações apresentadas nas Seções 5.4 e 5.5 mantivessem consistência e qualidade, permitindo identificar tendências epidemiológicas e apoiar a tomada de decisão em saúde pública.

A etapa de engenharia de dados, abordada nas Seções 5.2.1 a 5.2.5, evidenciou a robustez do *pipeline* proposto, embora o tempo de persistência no banco de dados (cerca de uma hora e meia, conforme observado na Seção 5.2.5) ainda represente um ponto de atenção para aplicações que exijam atualização em tempo quase real.

A validação do *framework* com a incorporação de um modelo preditivo simples (*Naive Baseline*), descrito na Seção 5.3, demonstrou a viabilidade de integrar algoritmos de previsão ao sistema, abrindo caminho para a utilização de modelos mais sofisticados que possam estimar indicadores como o número básico de reprodução (R_0) ou projeções de demanda hospitalar.

Os módulos analíticos apresentados nas Seções 5.5.1 a 5.5.6 (Resultados da Análise Epidemiológica) reforçam a aplicabilidade do *framework* para análises históricas, comparativas e de correlação, ainda que a interpretação epidemiológica detalhada seja realizada em estudos complementares - *veja, p. ex., (FARIAS, 2025)*. As comparações entre capitais, análise de mortalidade acumulada e cruzamento com a disponibilidade de leitos evidenciam o potencial da ferramenta para integrar múltiplos indicadores em uma mesma interface de análise.

Importante destacar que todo o código-fonte desenvolvido foi disponibilizado pu-

blicamente no repositório github.com/carloszan/covid. Essa decisão garante a reprodutibilidade dos resultados, permitindo que outros pesquisadores e profissionais de saúde possam replicar, auditar ou expandir as funcionalidades apresentadas neste estudo. A abertura do código também favorece a colaboração da comunidade científica, acelerando melhorias e adaptações do *framework* para novas aplicações.

A combinação entre o uso do Metabase (Seção 5.4), técnicas robustas de pré-processamento (Seção 5.2) e uma arquitetura modular orientada a objetos garante uma base sólida para evolução do sistema.

O *framework* não apenas atende às demandas atuais de monitoramento, mas também oferece um arcabouço sustentável para futuras expansões, contribuindo para o avanço da vigilância epidemiológica baseada em dados.

Em síntese, os resultados discutidos validam as escolhas metodológicas e tecnológicas adotadas, ao mesmo tempo em que apontam direções para melhorias, como a otimização da persistência de dados e a incorporação de modelos analíticos mais complexos. Essa evolução pode ampliar ainda mais o impacto da ferramenta no suporte a decisões rápidas e fundamentadas em contextos de emergência sanitária.

7 Conclusão

O presente trabalho teve como objetivo o desenvolvimento de um *framework* para monitoramento epidemiológico, aplicado ao contexto da pandemia de Covid-19. A abordagem proposta foi estruturada para ser modular, escalável e adaptável a diferentes cenários epidemiológicos, atendendo às lacunas identificadas nas ferramentas atualmente disponíveis.

Os resultados apresentados no Capítulo 5 demonstram que o *framework* atendeu aos objetivos estabelecidos na Seção 1.3. O tratamento e limpeza de dados (Seção 5.1) demonstraram eficácia na mitigação de inconsistências e na preservação da integridade das séries temporais. A arquitetura de engenharia de dados (Seção 5.2) mostrou-se robusta para consolidar grandes volumes de informações, embora o tempo de persistência no banco de dados (Seção 5.2.4) tenha sido identificado como um ponto a ser otimizado em versões futuras.

A validação por meio de um modelo preditivo simples (Seção 5.3) comprovou a viabilidade de integração entre coleta, pré-processamento, modelagem e visualização. Essa prova de conceito reforça que o *framework* pode incorporar modelos mais sofisticados, como projeções de demanda hospitalar ou cálculos de indicadores epidemiológicos avançados.

As análises apresentadas nas Seções 5.4.1 a 5.4.5 evidenciam que o uso do Metabase trouxe flexibilidade e acessibilidade na exploração de dados, permitindo a construção de *dashboards* adaptáveis a diferentes públicos, desde gestores até pesquisadores. Já os estudos comparativos e correlacionais descritos nas Seções 5.5.1 a 5.5.6 mostraram o potencial do sistema em agregar múltiplos indicadores e apoiar estudos epidemiológicos complementares.

Em um contexto em que crises sanitárias podem se disseminar rapidamente e exigir respostas rápidas, a ciência aberta e a colaboração entre diferentes áreas são fundamentais para a tomada de decisão baseada em evidências. Por isso todo o código-fonte desenvolvido foi disponibilizado publicamente no repositório github.com/carloszan/covid. Essa abertura garante a reprodutibilidade dos resultados e reforça o compromisso deste trabalho com a ciência aberta, permitindo que outros pesquisadores repliquem, validem ou expandam as funcionalidades propostas.

Ao combinar a disponibilização pública do código com o uso de ferramentas abertas, este trabalho contribui com um produto técnico replicável e também incentiva a consolidação de uma cultura colaborativa na produção científica e na gestão de dados de saúde.

7.1 Principais Contribuições

A aplicação de técnicas como *Z-score* e média móvel (Seção 5.1) permitiu a identificação e correção de *outliers*, assim como a suavização da série temporal, melhorando a consistência das análises, se comparado aos dados oficiais do Ministério da Saúde (SAUDE, 2020).

O *pipeline* modular desenvolvido em Python mostrou-se escalável, descrito na Seção 5.2, com tempos de execução aceitáveis mesmo em grandes volumes de dados (em média, 25,75 segundos para agrupamento, 144 segundos para limpeza e 151,2 segundos para engenharia de atributos). Mais uma vez, esses resultados demonstram valores promissores para uma ferramenta de monitoramento diário de surtos, mostrando-se eficiente sem se tornar um gargalo operacional.

A implementação de um modelo *Naive Baseline* demonstrou a viabilidade de incorporar previsões epidemiológicas no sistema de monitoramento contínuo dentro da ferramenta proposta, como mostrado na Seção 5.3. Isso é importante durante um surto, pois ao antever cenários epidemiológicos, permite a implementação proativa de medidas de contenção e alocação estratégica de recursos.

O painel interativo desenvolvido no Metabase permitiu a análise em diferentes níveis de granularidade (nacional, estadual e municipal), facilitando a identificação de tendências e a comparação entre regiões, exposto na Seção 5.4.

A estrutura modular do painel possibilita sua adaptação para outras doenças, reforçando sua aplicabilidade em diferentes cenários epidemiológicos, como apresentada na Seção 5.2. Ademais, um painel dessa natureza permite integrar múltiplos indicadores para estudos comparativos, apresentado na Seção 5.5.

Por fim, o código-fonte está disponível publicamente, assegurando reprodutibilidade e incentivo à colaboração científica, no endereço github.com/carloszan/covid.

7.2 Limitações e Desafios

A pesquisa enfrentou desafios significativos relacionados à qualidade dos dados, uma vez que a presença de valores negativos e atrasos na notificação em determinadas localidades comprometeu a confiabilidade das análises. Isso foi mitigado com o pré-processamento proposto na Seção 4.2.

Além disso, o processo de carregamento dos dados no banco de dados PostgreSQL representou um gargalo crítico no *pipeline*, consumindo em média 3 horas e 58 minutos para processar 10 milhões de registros, relatado na Seção 5.2.5. Outra limitação relevante foi o modelo preditivo *baseline* adotado, que, apesar de servir como referência inicial, não

considerou variáveis socioeconômicas ou de mobilidade urbana, restringindo sua aplicabilidade em cenários epidemiológicos mais complexos (Seção 5.3).

7.3 Trabalhos Futuros

Como direcionamentos para pesquisas futuras, destaca-se a necessidade de aprimorar o *pipeline* de dados por meio da implementação de estratégias de otimização específicas para diferentes tipos de consultas. Uma abordagem promissora seria a criação de tabelas pré-agregadas e materializadas, otimizadas para responder às perguntas analíticas mais frequentes, reduzindo assim a necessidade de processamento complexo em tempo real. Essa solução, combinada com técnicas de particionamento inteligente dos dados, poderia oferecer ganhos significativos de performance sem a complexidade operacional de sistemas de *streaming*.

A implementação de um sistema de *cache* inteligente para consultas frequentes e a criação de índices especializados para os padrões de acesso mais comuns também se mostram como alternativas viáveis para otimizar o desempenho do sistema como um todo, garantindo tempos de resposta adequados mesmo com o crescimento do volume de dados.

No âmbito da modelagem preditiva, recomenda-se a incorporação sistemática de variáveis externas - incluindo indicadores de mobilidade urbana, condições climáticas e dados demográficos - em modelos avançados de séries temporais como ARIMA e redes neurais recorrentes (LSTM), com o objetivo de aumentar a acurácia das previsões epidemiológicas. Adicionalmente, propõe-se o desenvolvimento de modelos especializados para surtos locais, que considerem adequadamente as particularidades regionais na dinâmica de disseminação de doenças.

Quanto à expansão do *framework*, sugere-se sua adaptação para monitoramento de outras doenças infecciosas de relevância para a saúde pública, como dengue e influenza, testando sua eficácia e escalabilidade em diferentes contextos epidemiológicos. Complementarmente, recomenda-se a integração de fontes diversificadas de dados, incluindo redes sociais e registros eletrônicos de unidades de saúde, para fortalecer os mecanismos de detecção precoce de surtos e melhorar a capacidade de resposta do sistema.

Além disso, também é possível expandir o trabalho buscando-se por outras técnicas de pré-processamento (apresentados 4.2), devido a importância da doença Covid-19 até hoje.

7.4 Considerações Finais

Esse trabalho foi parte integrante do projeto Fapemig intitulado ‘APQ- 02152-21: Buscando Pontos de Mudança nas Séries Temporais de COVID-19 do Estado de Mi-

nas Gerais’, com foco na plataforma computacional e subsidia o trabalho epidemiológico de (FARIAS, 2025). O *framework* desenvolvido representa uma contribuição significativa para a vigilância epidemiológica baseada em dados. Ao oferecer uma solução que combina robustez técnica, flexibilidade analítica e acessibilidade para usuários de diferentes perfis, o sistema se apresenta como uma ferramenta estratégica para respostas rápidas e fundamentadas em saúde pública, tanto em cenários de emergência quanto no acompanhamento contínuo de doenças. A disponibilização aberta do código-fonte amplia o impacto do trabalho, garantindo transparência, reprodutibilidade e estímulo à inovação colaborativa.

Referências

- MENEZES, M.; NERI, Y. *Instituto Oswaldo Cruz confirma circulação de nova variante da Covid-19 no Rio de Janeiro*. 2025. <https://fiocruz.br/noticia/2025/07/instituto-oswaldo-cruz-confirma-circulacao-de-nova-variante-da-covid-19-no-rio-de-janeiro>. Acessado em: 2025-07-28.
- SECOM. *Estado decreta situação de emergência em saúde pública diante do aumento de doenças respiratórias*. 2025. <https://www.agenciaminas.mg.gov.br/noticia/governo-de-minas-decreta-situacao-de-emergencia-em-saude-publica-diante-do-aumento-de-doencas-respiratorias>. Acessado em: 2025-07-28.
- MILAGRES, L. *Cidades de Minas Gerais decretam emergência em saúde pública; veja lista de municípios*. 2025. <https://g1.globo.com/mg/minas-gerais/noticia/2025/05/03/cidades-de-minas-gerais-decretam-emergencia-em-saude-publica-veja-lista-de-municipios.ghtml>. Acessado em: 2025-07-28.
- FARIAS, L. R. *Análise epidemiológica de Covid-19 nos estados brasileiros no primeiro ano de pandemia*. Ouro Preto: [s.n.], 2025. 110 p.
- SHI, Y.; WANG, G.; CAI, X.-p.; DENG, J.-w.; ZHENG, L.; ZHU, H.-h.; ZHENG, M.; YANG, B.; CHEN, Z. An overview of covid-19. *Journal of Zhejiang University. Science. B*, v. 21, n. 5, p. 343, 2020.
- RODRIGUES, G. M.; ORTEGA, E. M. M. *Florestas aleatórias de sobrevivência e modelos de regressão para análise de dados de covid-19 do datasus*. Galoá, 2023.
- SANTOS, D. A. dos; FARIA, D. A. de; RIBEIRO, G. P.; LUCIANO, L. A.; SILVA, M. E. A. C. da; SANTOS, S. C. dos; ARAÚJO, D. C. S. Perfil epidemiológico dos casos e óbitos de síndrome respiratória aguda grave com ênfase em covid-19 no estado de minas gerais brasil 2021 a 2023. *Research, Society and Development*, v. 13, n. 7, p. e12113746349–e12113746349, 2024.
- OLIVEIRA, G. G. R. de; NOBRE, C. N. The use of machine learning to predict hospitalization of covid-19: A case study in the state of minas gerais-brazil. In: *HEALTHINF*. [S.l.: s.n.], 2023. p. 392–399.
- FERNANDES, A. G.; ANDRADE, C. L. O. de; SOUZA, M. C. de; DUQUE, A. C. M. Morbimortalidade por pneumonia no estado da bahia no período pré e durante a pandemia de covid-19: base de dados do datasus. *Revista de Ciências Médicas e Biológicas*, v. 22, n. 1, p. 47–51, 2023.
- SILVA, L. G. d.; BEZERRA, I. M. P.; SANTOS, G. L.; ABREU, L. C. d. Comparative analysis of epidemiological outcome of incidence, mortality and lethality by covid-19 between the states of espírito santo and minas gerais, brazil. *Epidemiologia*, MDPI, v. 5, n. 2, p. 250–266, 2024.
- MARTIN, R. C. Design principles and design patterns. *Object Mentor*, v. 1, n. 34, p. 597, 2000.

- MOORTHY, R.; UDUPA, S.; BHAGAVATH, S. A.; RAO, V. Centralized and automated healthcare systems: A essential smart application post covid-19. In: IEEE. *2020 3rd international conference on intelligent sustainable systems (ICISS)*. [S.l.], 2020. p. 131–138.
- WARD, S.; LINDSLEY, A.; COURTER, J.; ASSA'AD, A. Clinical testing for covid-19. *Journal of allergy and clinical immunology*, Elsevier, v. 146, n. 1, p. 23–34, 2020.
- ANDRADE, C. Z scores, standard scores, and composite test scores explained. *Indian journal of psychological medicine*, SAGE Publications Sage India: New Delhi, India, v. 43, n. 6, p. 555–557, 2021.
- RODRÍGUEZ, P.; BAUTISTA, M. A.; GONZALEZ, J.; ESCALERA, S. Beyond one-hot encoding: Lower dimensional target embedding. *Image and Vision Computing*, Elsevier, v. 75, p. 21–31, 2018.
- JIA, B.-B.; ZHANG, M.-L. Multi-dimensional classification via sparse label encoding. In: PMLR. *International conference on machine learning*. [S.l.], 2021. p. 4917–4926.
- SANTOS, B.; SÉRIO, F.; ABRANTES, S.; SÁ, F.; LOUREIRO, J.; WANZELLER, C.; MARTINS, P. Open source business intelligence tools: Metabase and redash. In: *KDIR*. [S.l.: s.n.], 2019. p. 467–474.
- BUDIARTI, R. P. N.; SUKARIDHOTO, S.; ZUHDI, U.; RASYID, A.; SONHAJI, A. I. Implementation of big data information system using open-source metabase for civil registration and vital statistics data visualization in surabaya. *JOIV: International Journal on Informatics Visualization*, v. 7, n. 4, p. 2358–2365, 2023.
- SAUDE, M. da. *Coronavírus Brasil*. 2020. <https://covid.saude.gov.br/>. Acessado em: 2025-08-13.
- DIAS, V.; CARNEIRO, M.; VIDAL, C.; CORRADI, M.; BRANDÃO, D.; CUNHA, C.; CHEBABO, A.; OLIVEIRA, P.; MICHELIN, L.; ROCHA, J. L. L. Orientações sobre diagnóstico, tratamento e isolamento de pacientes com covid-19. *J Infect Control*, v. 9, n. 2, p. 56–75, 2020.
- HERZEN, J. Darts: User-friendly modern machine learning for time series. *Journal of Machine Learning Research*, v. 23, p. 1–6, 2022. Disponível em: <<https://arxiv.org/abs/2110.0322>>.
- VOHRA, D. Apache parquet. In: *Practical Hadoop Ecosystem: A Definitive Guide to Hadoop-Related Frameworks and Tools*. [S.l.]: Springer, 2016. p. 325–335.

Anexos

ANEXO A – Logs de Execução do Framework

```

2025-07-24 14:09:23 - INFO - Iniciando processo: agrupar
2025-07-24 14:09:23 - INFO - Processo agrupar iniciado
2025-07-24 14:09:23 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2020_Parte1_18jul2025.csv
2025-07-24 14:09:24 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2020_Parte2_18jul2025.csv
2025-07-24 14:09:25 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2021_Parte1_18jul2025.csv
2025-07-24 14:09:26 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2021_Parte2_18jul2025.csv
2025-07-24 14:09:28 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2022_Parte1_18jul2025.csv
2025-07-24 14:09:30 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2022_Parte2_18jul2025.csv
2025-07-24 14:09:31 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2023_Parte1_18jul2025.csv
2025-07-24 14:09:33 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2023_Parte2_18jul2025.csv
2025-07-24 14:09:34 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2024_Parte1_18jul2025.csv
2025-07-24 14:09:36 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2024_Parte2_18jul2025.csv
2025-07-24 14:09:38 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2025_Parte1_18jul2025.csv
2025-07-24 14:09:41 - INFO - Lendo arquivo
    HIST_PAINEL_COVIDBR_2025_Parte2_18jul2025.csv
2025-07-24 14:09:52 - INFO - Parquet salvo com nome dados/0.raw.
    parquet
2025-07-24 14:09:52 - INFO - Processo agrupar finalizado
2025-07-24 14:09:53 - INFO - Processo concluído com sucesso:
    agrupar
2025-07-24 14:09:53 - INFO - Iniciando processo: limpar
2025-07-24 14:09:53 - INFO - Lendo dados/0.raw.parquet
2025-07-24 14:09:56 - INFO - Lido
2025-07-24 14:09:56 - INFO - Processando municipios_unicos
2025-07-24 14:09:58 - INFO - Processamento concluído

```



```
2025-07-24 14:09:58 - INFO - Filtrando o dataframe
2025-07-24 14:11:16 - INFO - Processamento concluido
2025-07-24 14:11:16 - INFO - Processando grupos
2025-07-24 14:11:16 - INFO - Processamento concluido
Processando: 99%| 5570/5598 [00:43<00:00, 128.33it/s]
2025-07-24 14:12:26 - INFO - Parquet salvo com nome dados/1.limpo
.parquet
2025-07-24 14:12:27 - INFO - Processo concluido com sucesso:
limpar
2025-07-24 14:12:27 - INFO - Iniciando processo:
computar_atributos
2025-07-24 14:12:27 - INFO - Lendo arquivo dados/1.limpo.parquet
2025-07-24 14:12:37 - INFO - Arquivo lido
2025-07-24 14:12:37 - INFO - Processando engenharia de atributos
2025-07-24 14:14:44 - INFO - Processado
2025-07-24 14:14:44 - INFO - Salvando arquivo
2025-07-24 14:15:06 - INFO - Parquet salvo com nome dados/2.
atributos.parquet
2025-07-24 14:15:07 - INFO - Processo concluido com sucesso:
computar_atributos
2025-07-24 14:15:07 - INFO - Iniciando processo: salvar_sql
2025-07-24 14:15:07 - INFO - Lendo dados/2.atributos.parquet
2025-07-24 14:15:16 - INFO - Lido
2025-07-24 14:15:16 - INFO - Salvando no banco Postgres
2025-07-24 17:21:37 - INFO - Salvo
2025-07-24 17:21:38 - INFO - Processo concluido com sucesso:
salvar_sql
```

ANEXO B – Logs de Execução do Algoritmo de Agrupamento

```
2025-07-22 14:03:37 - INFO - Iniciando processo: agrupar
2025-07-22 14:04:06 - INFO - Processo concluído com sucesso:
    agrupar

2025-07-22 22:09:19 - INFO - Iniciando processo: agrupar
2025-07-22 22:09:46 - INFO - Processo concluído com sucesso:
    agrupar

2025-07-23 16:07:42 - INFO - Processo agrupar iniciado
2025-07-23 16:08:06 - INFO - Processo concluído com sucesso:
    agrupar

2025-07-24 14:09:23 - INFO - Processo agrupar iniciado
2025-07-24 14:09:52 - INFO - Processo concluído com sucesso:
    agrupar
```

ANEXO C – Logs de Execução do Algoritmo de Limpeza

```
2025-07-22 14:04:06 - INFO - Iniciando processo: limpar
2025-07-22 14:06:42 - INFO - Processo concluido com sucesso:
    limpar

2025-07-22 22:09:46 - INFO - Iniciando processo: limpar
2025-07-22 22:11:55 - INFO - Processo concluido com sucesso:
    limpar

2025-07-23 16:08:06 - INFO - Iniciando processo: limpar
2025-07-23 16:10:23 - INFO - Processo concluido com sucesso:
    limpar

2025-07-24 14:09:53 - INFO - Iniciando processo: limpar
2025-07-24 14:12:27 - INFO - Processo concluido com sucesso:
    limpar
```

ANEXO D – Logs de Execução do Algoritmo de Computar Atributos

```
2025-07-22 14:06:42 - INFO - Iniciando processo:
    computar_atributos
2025-07-22 14:09:28 - INFO - Processo concluido com sucesso:
    computar_atributos

2025-07-22 22:11:55 - INFO - Iniciando processo:
    computar_atributos
2025-07-22 22:14:18 - INFO - Processo concluido com sucesso:
    computar_atributos

2025-07-23 16:10:23 - INFO - Iniciando processo:
    computar_atributos
2025-07-23 16:12:44 - INFO - Processo concluido com sucesso:
    computar_atributos

2025-07-24 14:12:27 - INFO - Iniciando processo:
    computar_atributos
2025-07-24 14:15:07 - INFO - Processo concluido com sucesso:
    computar_atributos
```

ANEXO E – Logs de Execução do Algoritmo de Carregamento

```
2025-07-22 14:09:28 - INFO - Iniciando processo: salvar_sql
2025-07-22 17:41:13 - INFO - Processo concluido com sucesso:
    salvar_sql

2025-07-23 16:12:44 - INFO - Iniciando processo: salvar_sql
2025-07-23 21:31:02 - INFO - Processo concluido com sucesso:
    salvar_sql

2025-07-24 14:15:07 - INFO - Iniciando processo: salvar_sql
2025-07-24 17:21:38 - INFO - Processo concluido com sucesso:
    salvar_sql
```

ANEXO F – Código Principal

```
def main():  
    pasta = 'dados'  
  
    agrupar(pasta)  
    limpar(pasta)  
    computar_atributos(pasta)  
    salvar_sql(pasta)  
  
if __name__ == "__main__":  
    main()
```

ANEXO G – Trecho do código de Limpeza

```
def _limpar(df):
    """
    Executa o pipeline completo de limpeza e processamento dos dados.

    Realiza sequencialmente as seguintes operacoes:
    1. Suaviza os dados para remocao de outliers
    2. Recalcula os casos acumulados com base nos dados suavizados

    Args:
        df (pd.DataFrame): DataFrame original a ser processado,
        deve conter a coluna 'casosNovos'.

    Returns:
        pd.DataFrame: DataFrame processado com:
        - Dados suavizados na coluna 'novos_casos_novos'
        - Casos acumulados recalculados
        na coluna 'novos_casos_acumulados'

    Example:
        >>> df_limpo = _limpar(df_original)
        Retorna o DataFrame apos suaviza o e calculo de acumulados
    """
    df = __suavizar(df)
    df = __remover_por_zscore(df)
    df = __remover_negativos(df)
    df = __recalcula_casos_acumulados(df)
    return df
```

ANEXO H – Código Suavizar

```
def _suavizar(df, window_size=7, threshold=2):
    """
    Smooth data by rolling mean.
    Df must be indexed.

    Parameters:
    - df: pandas DataFrame with columns 'date' and 'casosNovos'
    - window_size: number of days to consider in rolling window
    - threshold: number of standard deviations to use for outlier detection

    Returns:
    - DataFrame with smoothed values
    """
    # Make a copy to avoid modifying original data
    df_smoothed = df.copy()

    # Calculate rolling statistics
    rolling_mean = df['casosNovos'].rolling(
        window=window_size, center=False, closed='left').mean()

    df_smoothed['novos_casos_novos'] = pd.concat(
        [df['casosNovos'][0:window_size], rolling_mean[window_size:]]

    return df_smoothed
```